

A human brain is shown in profile, facing right. It is covered in vibrant, multi-colored paint splashes and drips. The colors include bright yellow, orange, red, magenta, blue, green, and black. The paint appears to be splattered from the top and back of the brain, creating a dynamic and artistic effect. The background is a plain, light color.

# Fundamentos de las Redes Neuronales

## Algoritmo de Retropropagación

**Clase 5**


Dra. Wendy Aguilar

# Modelos Generativos Profundos




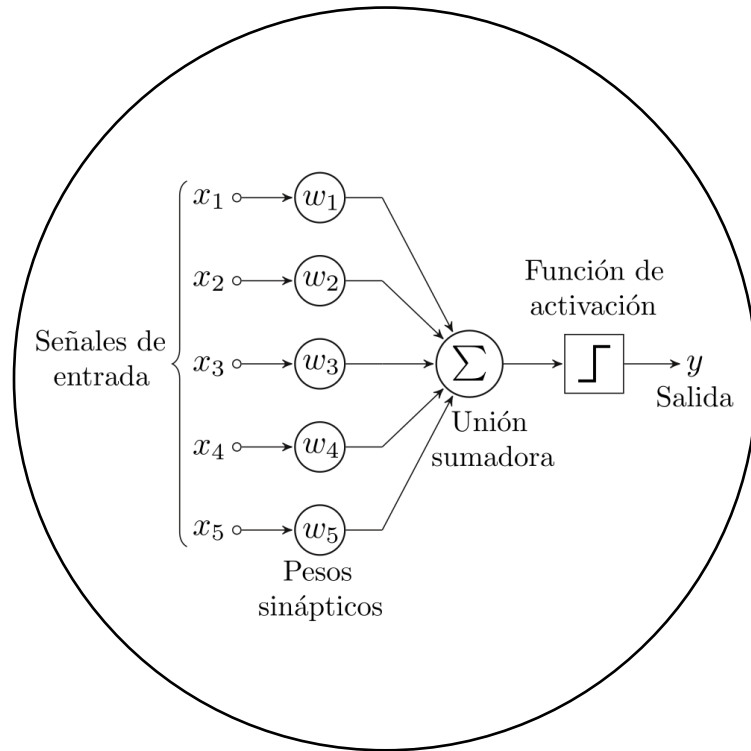
UN ENFOQUE DESDE LA  
CREATIVIDAD  
COMPUTACIONAL

¿cómo podemos entrenar  
un perceptrón con capas  
ocultas de forma eficiente?

¿cómo actualizar los pesos y sesgos?



# Perceptrones Multicapa y Aprendizaje de Pesos



En el perceptrón, una regla de aprendizaje para actualizar pesos es relativamente fácil de derivar, mientras no existan capas ocultas.

La entrada se transforma una sola vez por el perceptrón para calcular un valor de salida → los pesos pueden ajustarse directamente para producir la salida.

Cuando existen capas ocultas entre la entrada y salida, el problema se vuelve más complejo.

¿cuándo debemos modificar los pesos internos para calcular las activaciones que alimentan la salida final?

¿Cómo debemos ajustarlos en relación con los pesos de entrada?



# Perceptrones Multicapa y Retropropagación

- En la década de los **80s**, el **algoritmo de retropropagación** surgió como una solución práctica para el cálculo de los pesos ocultos.



La idea clave es que:


- podemos utilizar la **regla de la cadena** del cálculo diferencial para **calcular de manera eficiente las derivadas de cada parámetro** de una red con respecto a una función de pérdida,
- y **combinándola con una regla de aprendizaje**, obtener un método escalable para entrenar redes multicapa.

# Notación

\* Se le llama oculta porque sus valores son desconocidos (no observables) para el conjunto de entrenamiento.


Capa de entrada      Capa oculta      Capa salida

Número de capa




RN con 1 capa oculta y 2 capas totales

No se cuenta la capa de entrada.  
Solo se cuentan las capas con  
parámetros entrenables.



RN con ? capas ocultas y ? capas totales




RN con ? capas ocultas y ? capas totales

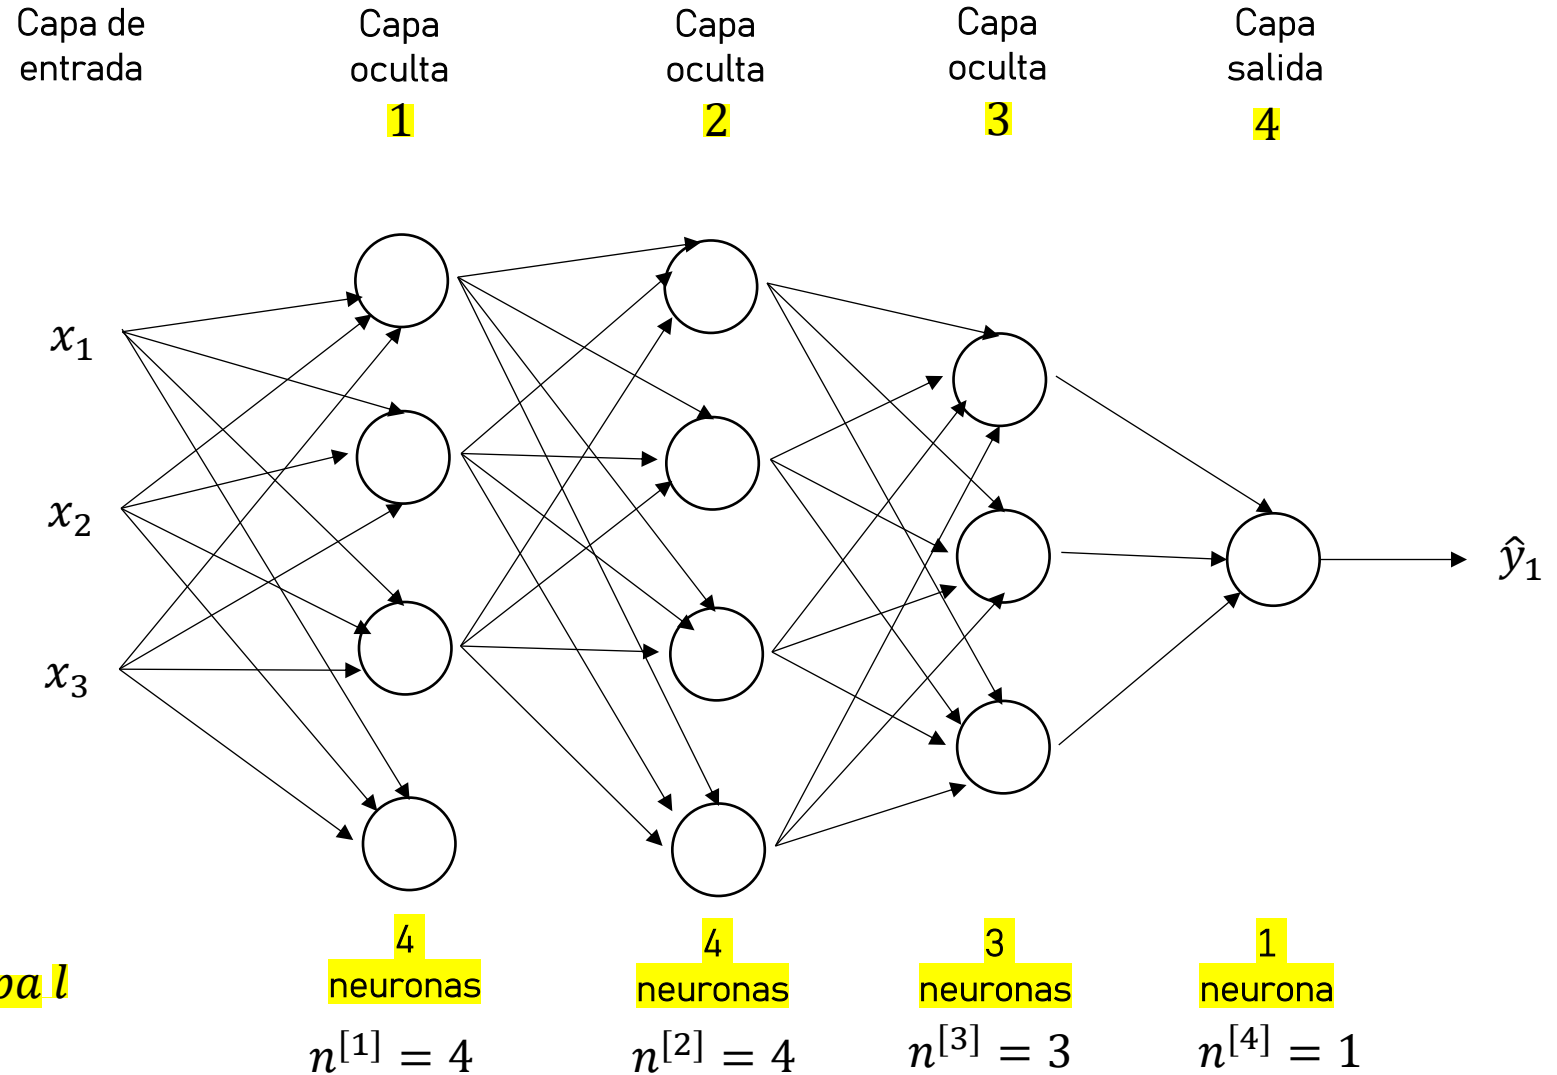
# Notación

RN de 4 capas

$L = \text{número de capas} = 4$

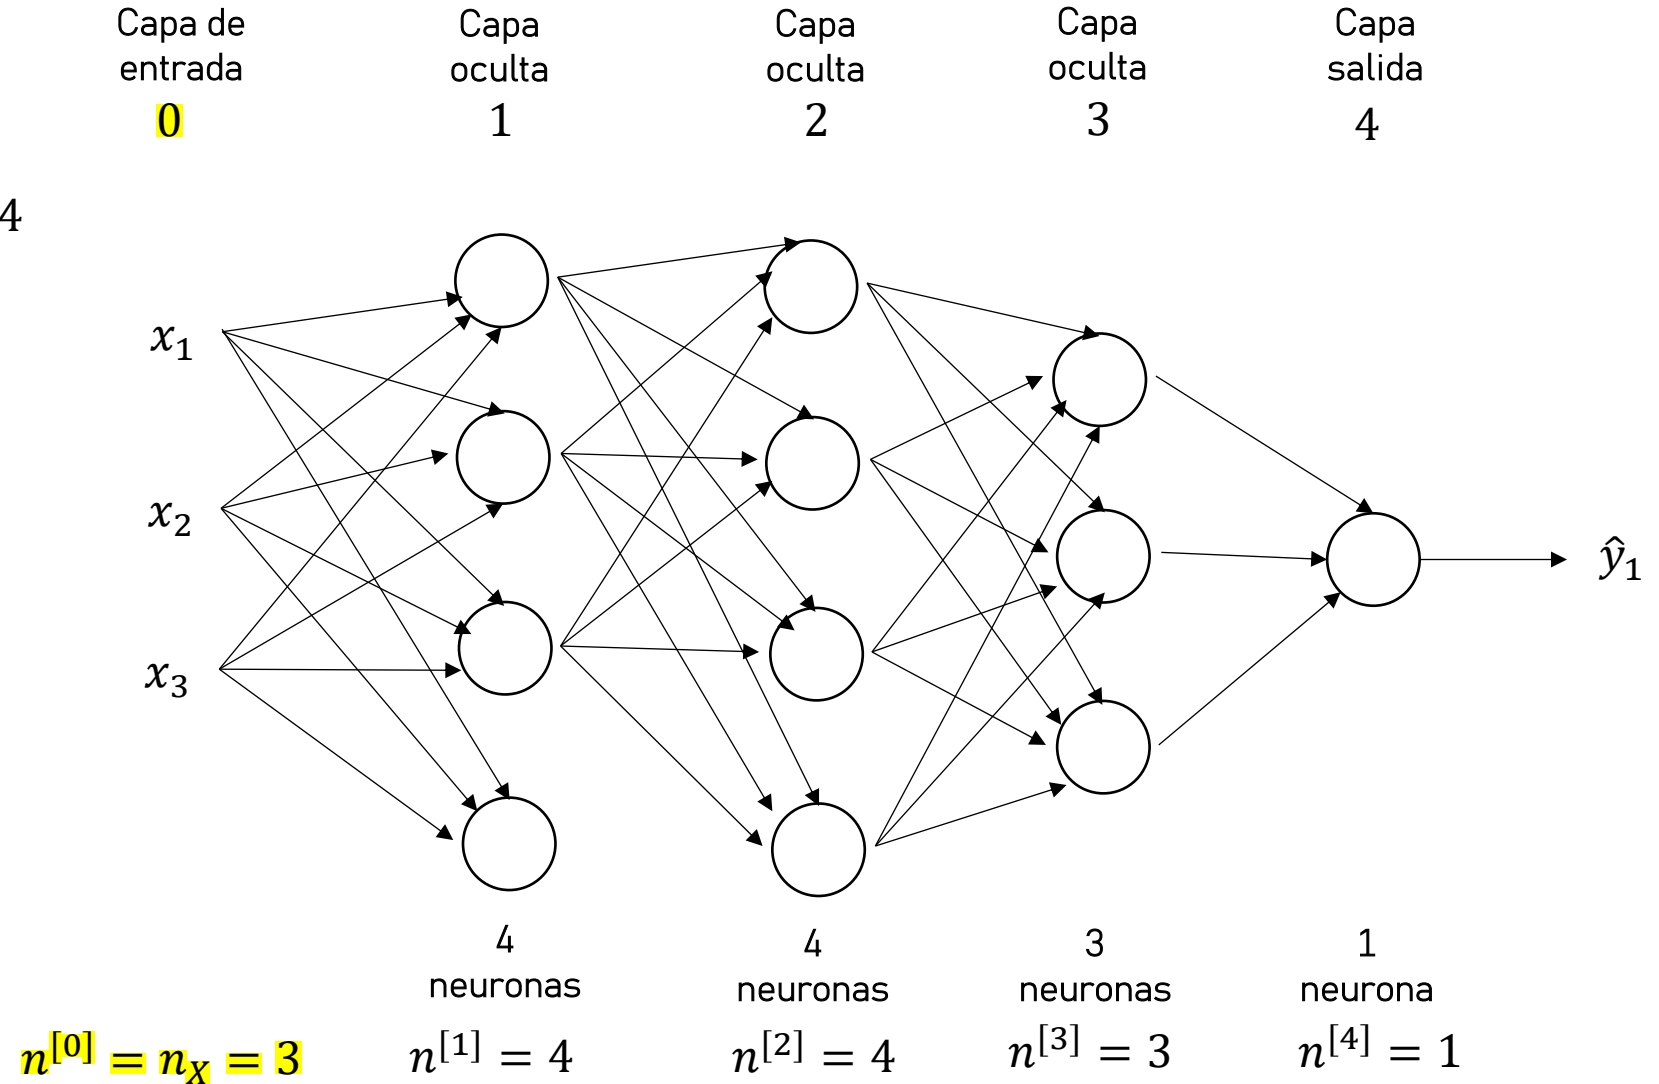


$n^l = \text{número de neuronas de la capa } l$




# Notación

RN de 4 capas  
 $L = \text{número de capas} = 4$

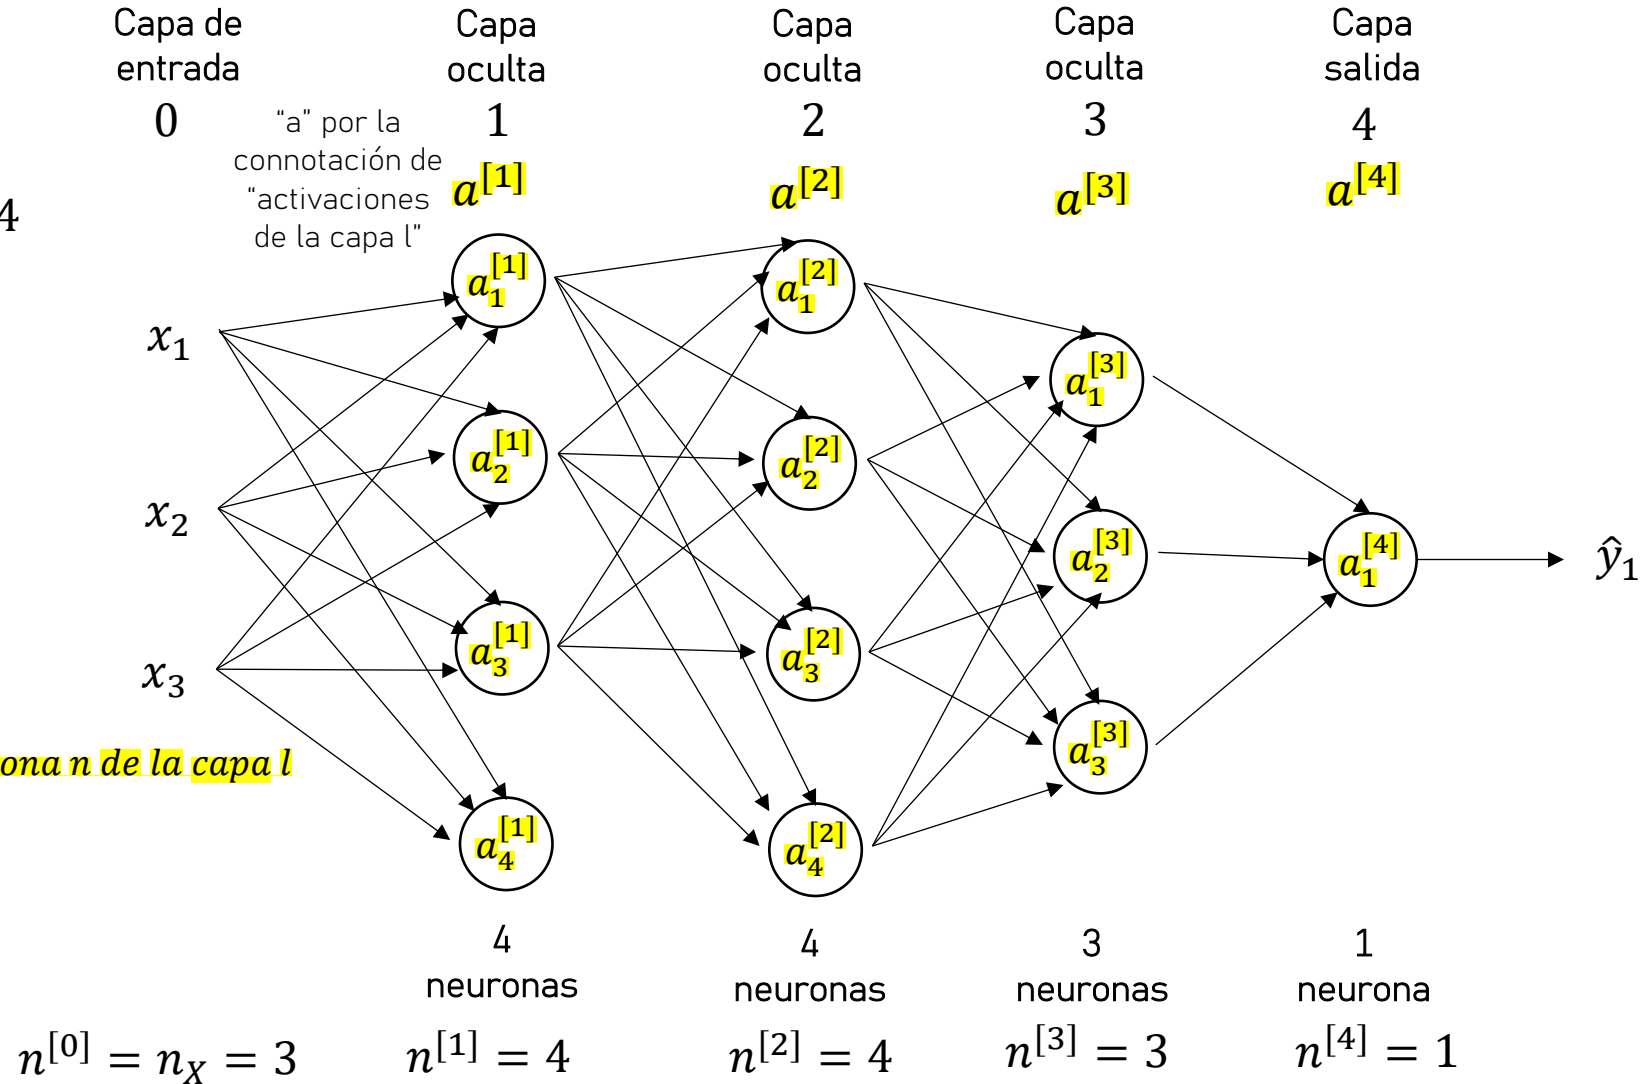


# Notación

RN de 4 capas  
 $L = \text{número de capas} = 4$

$$a^{[l]} = f^{[l]} \left( \sum_{i=1}^N w_i x_i + b \right)$$


$a_n^{[l]}$  = la activación de la la neurona  $n$  de la capa  $l$





# Notación

RN de 4 capas  
 $L = \text{número de capas} = 4$

$$a^{[l]} = g^{[l]}(z^{[l]})$$

$$z^{[l]} = \sum_{i=1}^N w_i x_i + b$$

$a_n^{[l]}$  = la activación de la neurona  $n$  de la capa  $l$

$w^{[l]}$  = pesos de  $z^{[l]}$

$w_{i,j}^{[l]}$  = el peso a la neurona destino  $i$  (de la capa  $l$ ) de la neurona de origen  $j$

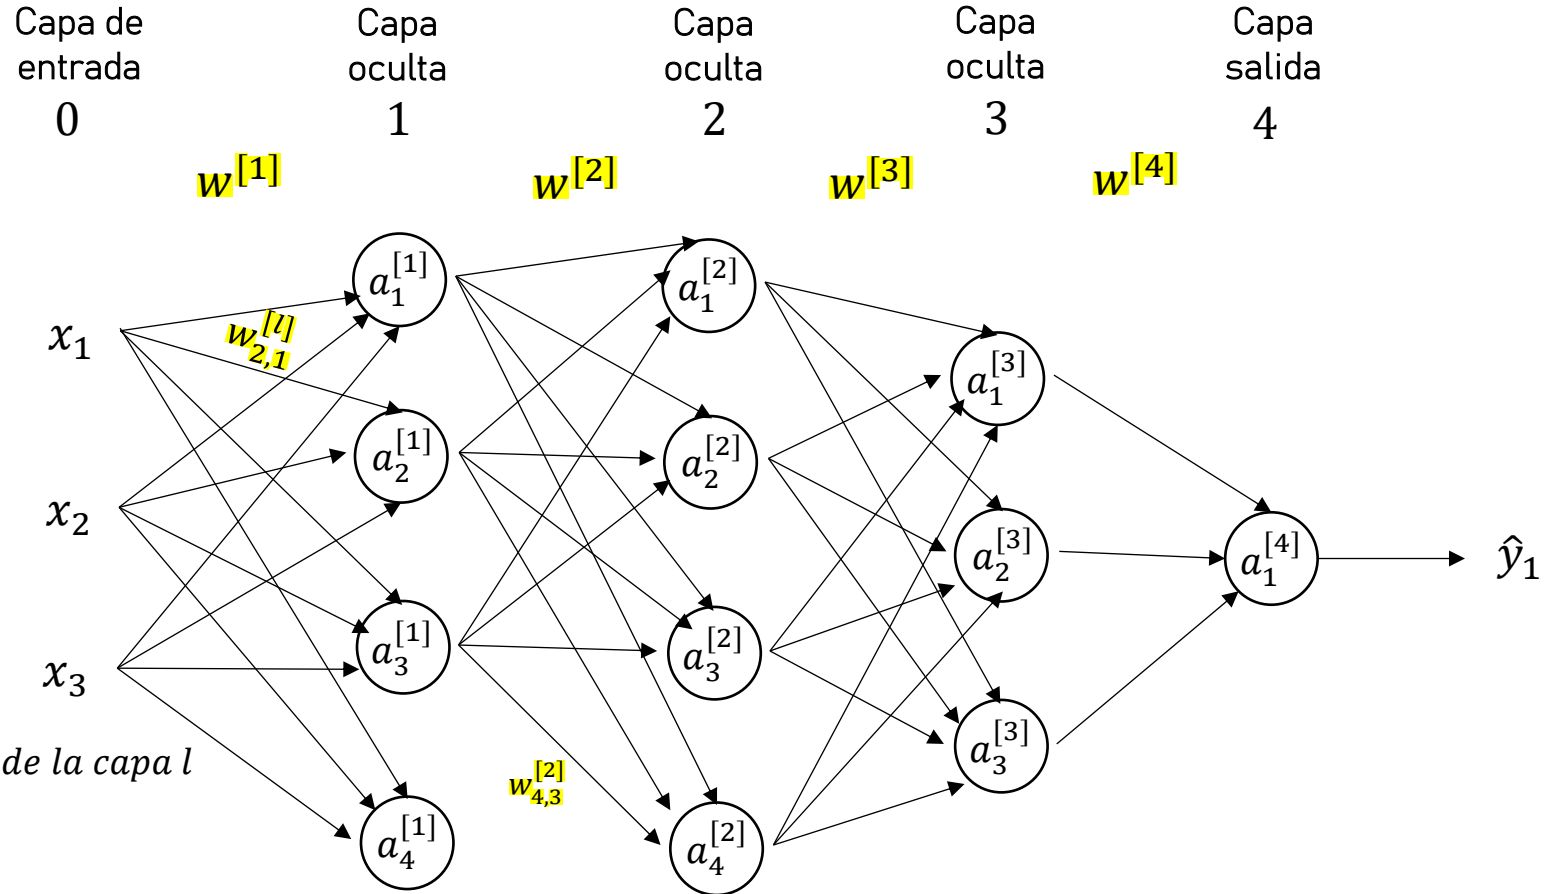
$$n^{[0]} = n_X = 3$$

$$n^{[1]} = 4$$

$$n^{[2]} = 4$$

$$n^{[3]} = 3$$

$$n^{[4]} = 1$$



# Notación

RN de 4 capas  
 $L = \text{número de capas} = 4$

$$a^{[l]} = g^{[l]}(z^{[l]})$$


$$z^{[l]} = \sum_{i=1}^N w_i x_i + b$$

$a_n^{[l]}$  = la activación de la la neurona  $n$  de la capa  $l$

$w^{[l]}$  = pesos de  $z^{[l]}$

$w_{i,j}^{[l]}$  = el peso a la neurona destino  $i$  (de la capa  $l$ ) de la neurona de origen  $j$

$b^{[l]}$  = sesgo de  $z^{[l]}$



# Notación

RN de 4 capas  
 $L = \text{número de capas} = 4$

$$a^{[l]} = g^{[l]}(z^{[l]})$$


$$z^{[l]} = \sum_{i=1}^N w_i x_i + b$$

$a_n^{[l]}$  = la activación de la la neurona  $n$  de la capa  $l$

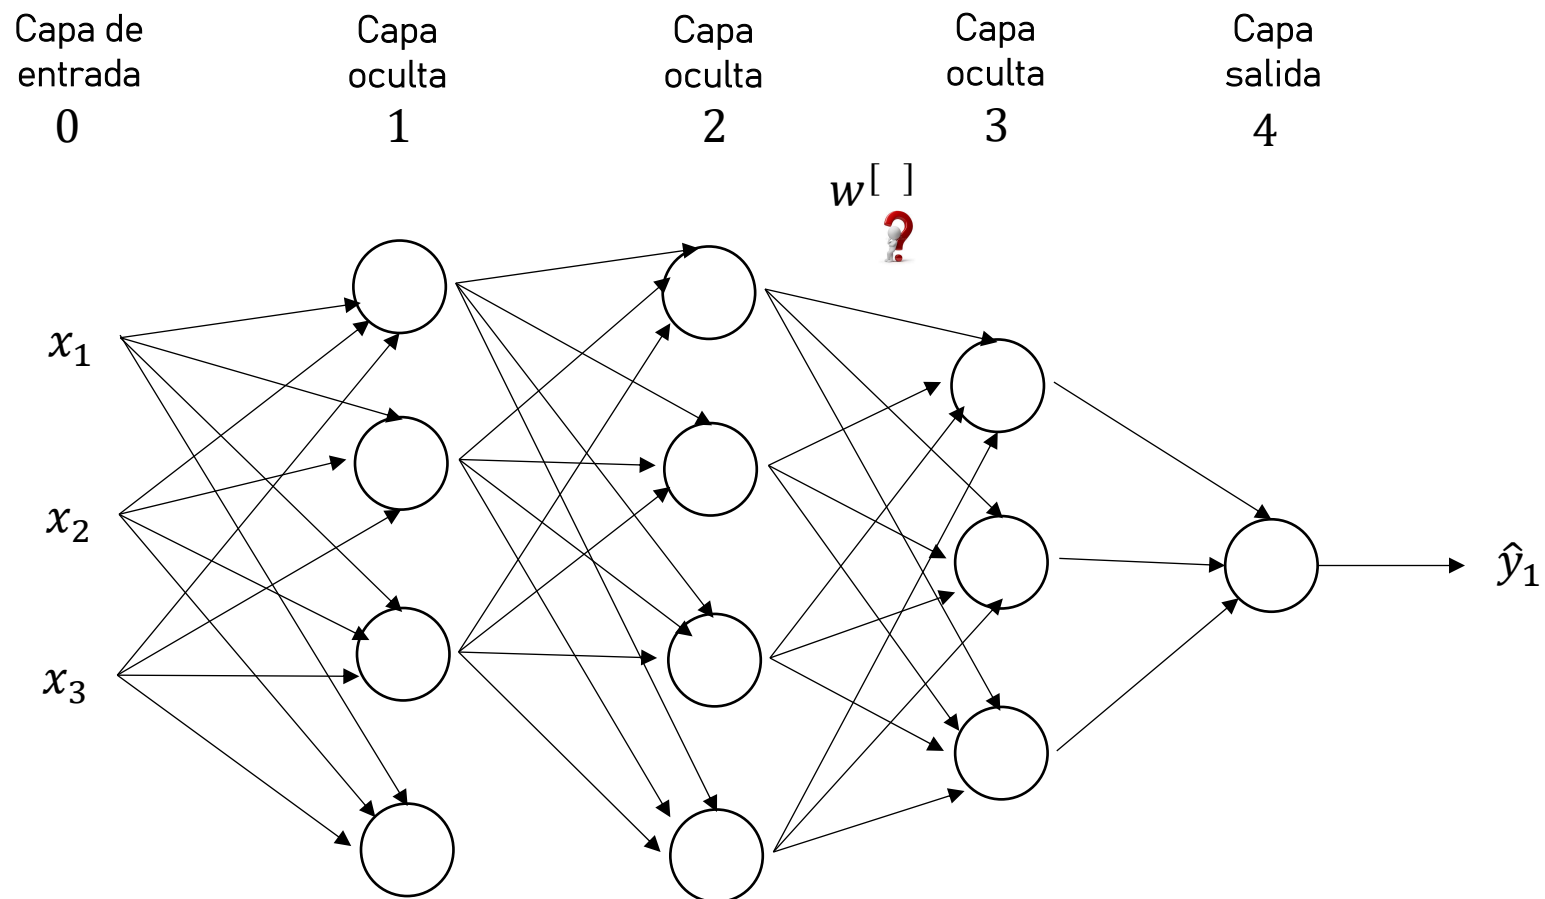
$w^{[l]}$  = pesos de  $z^{[l]}$

$w_{i,j}^{[l]}$  = el peso a la neurona destino  $i$  (de la capa  $l$ ) de la neurona de origen  $j$

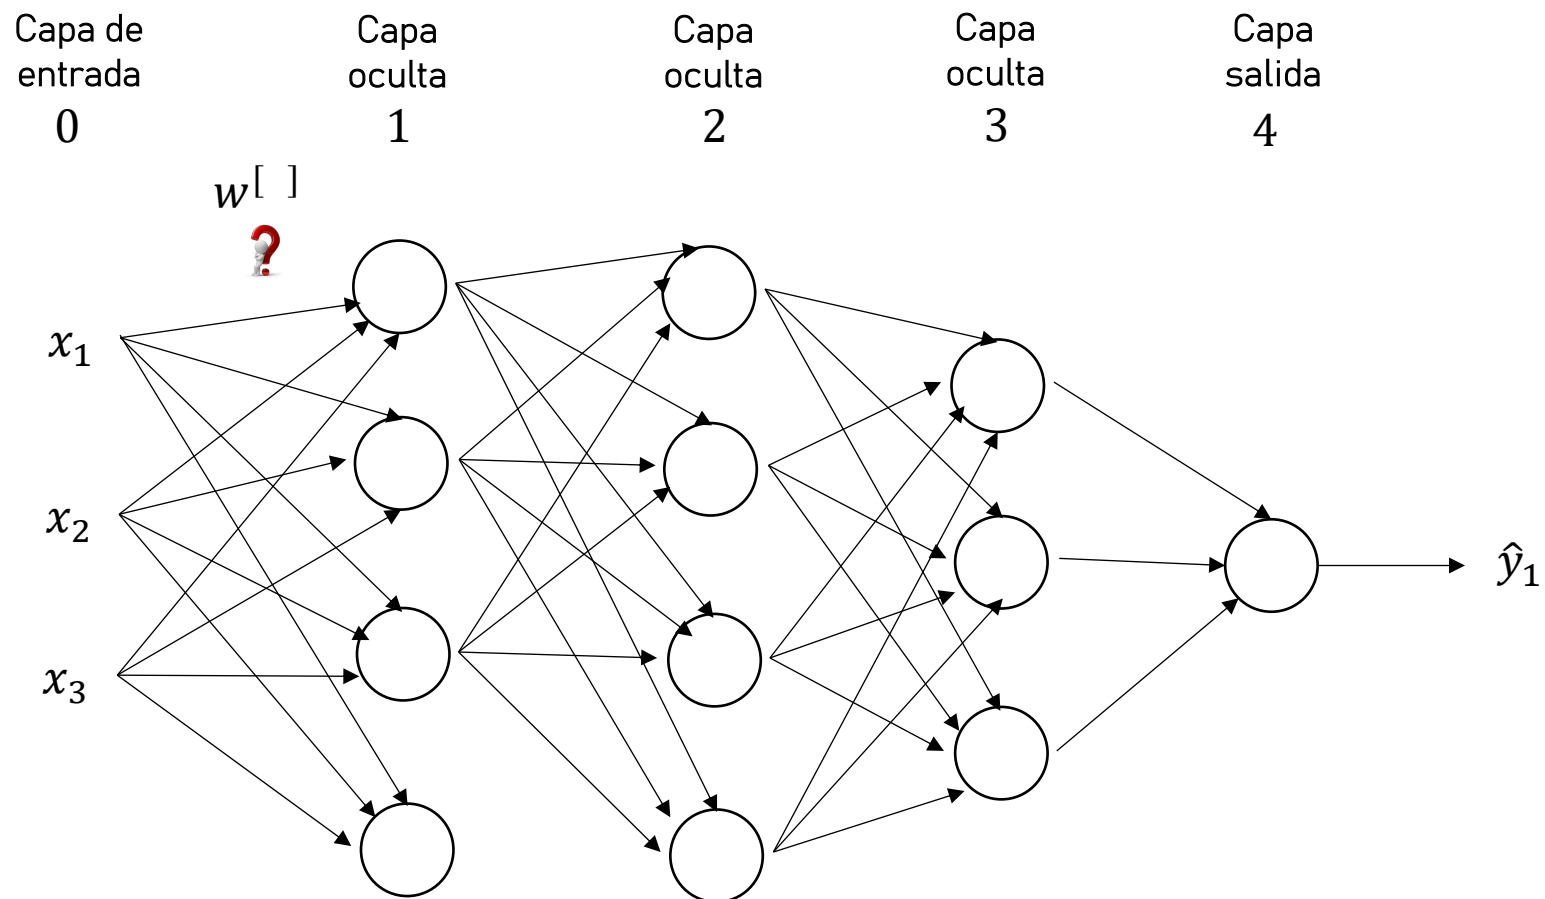
$b^{[l]}$  = sesgo de  $z^{[l]}$



# Notación

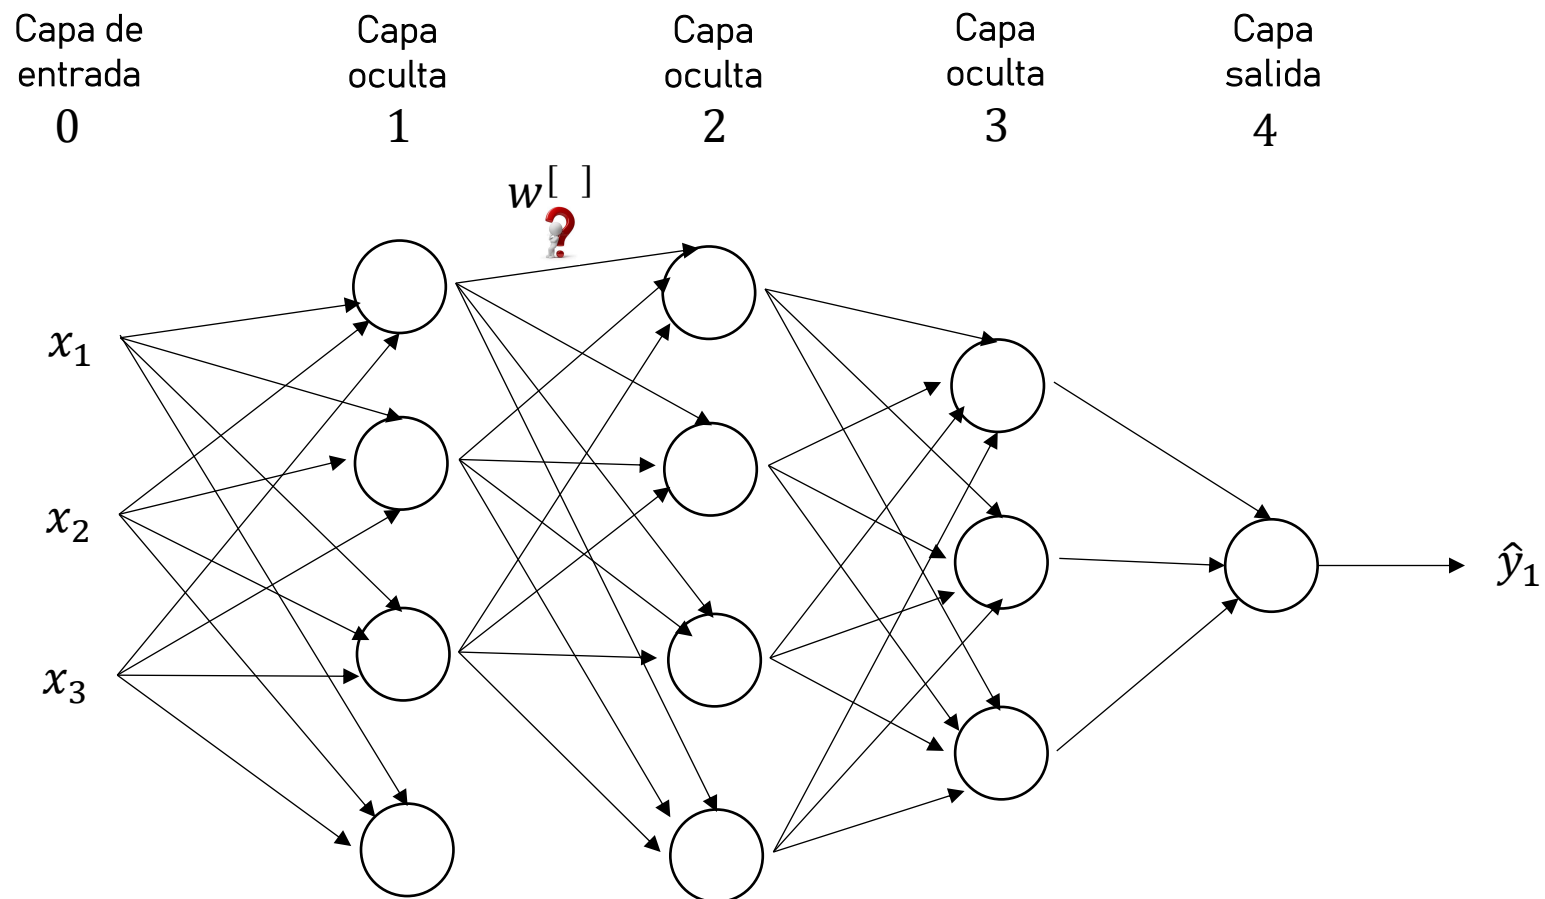


# Notación

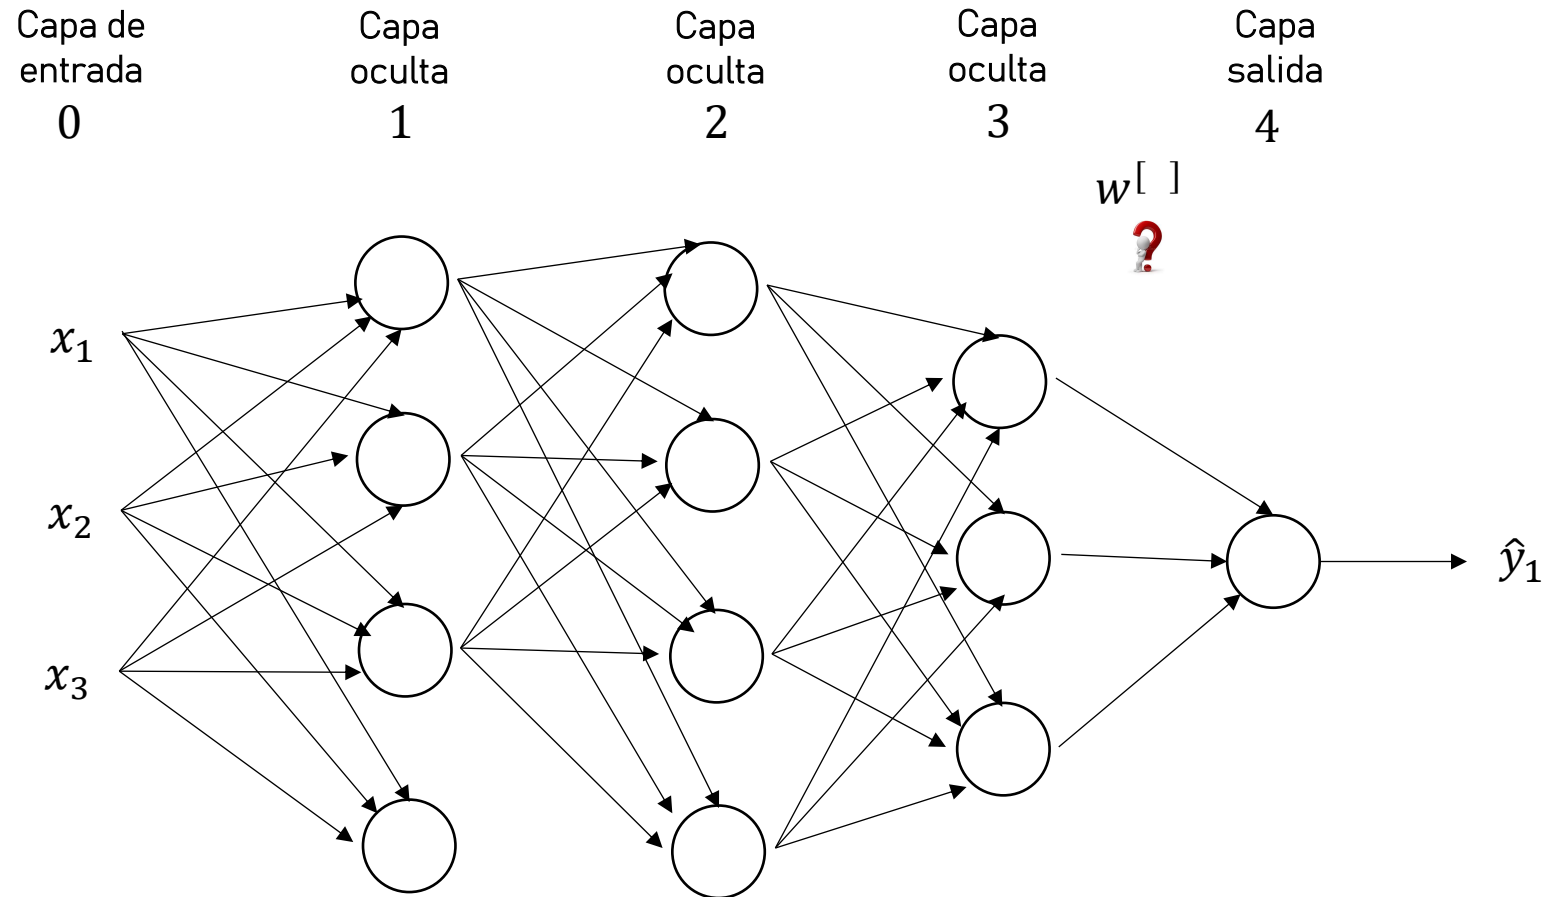




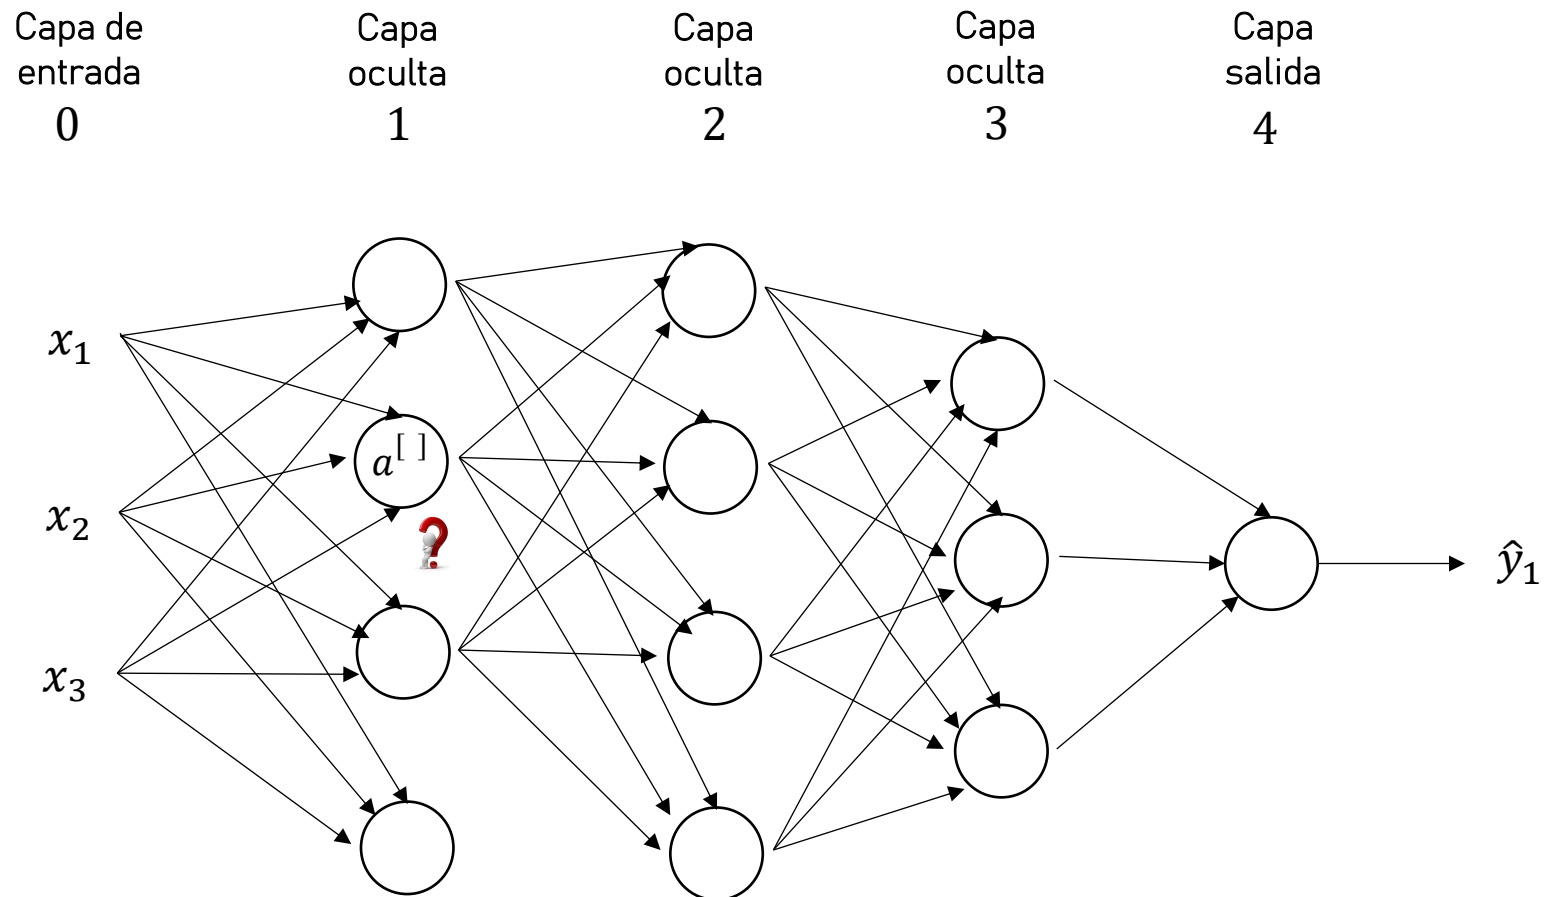
# Notación



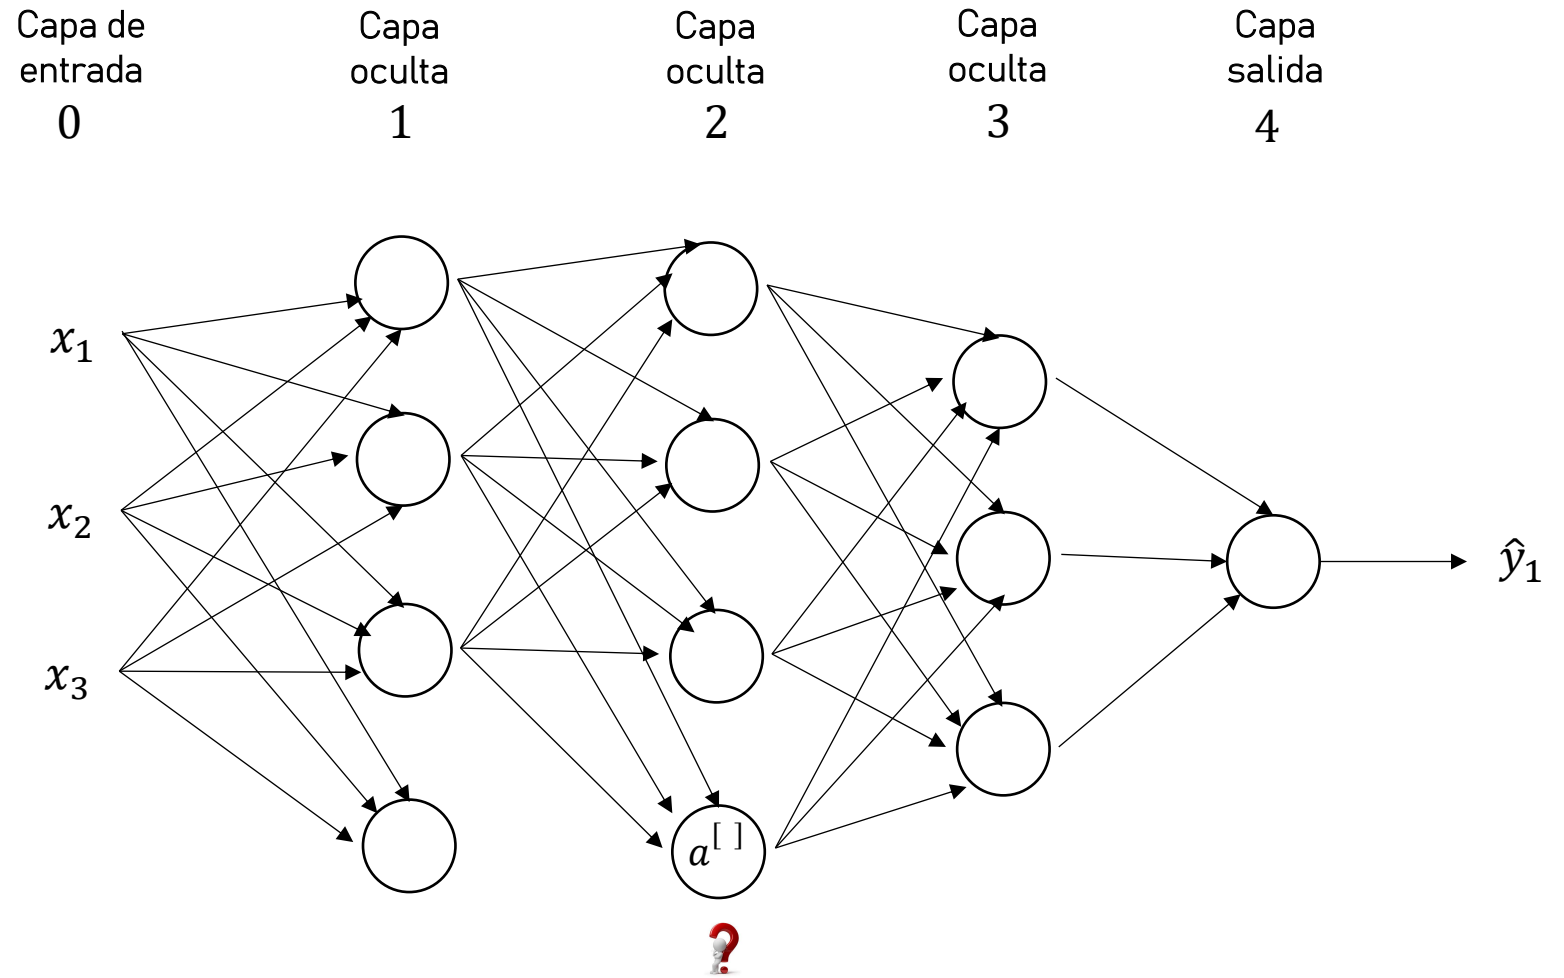
# Notación



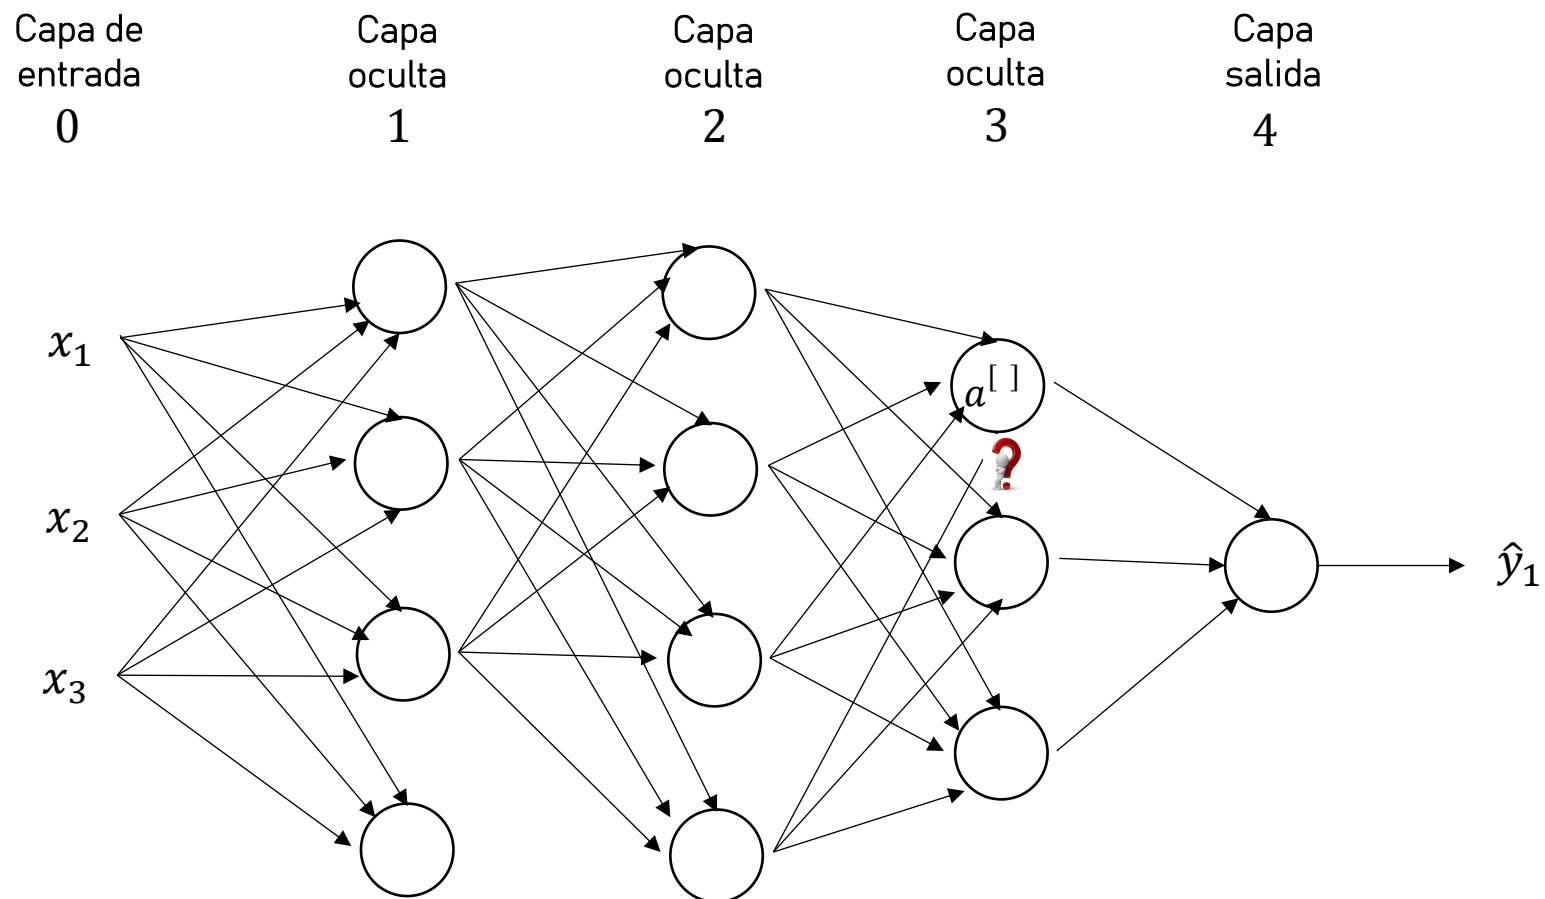
# Notación



# Notación

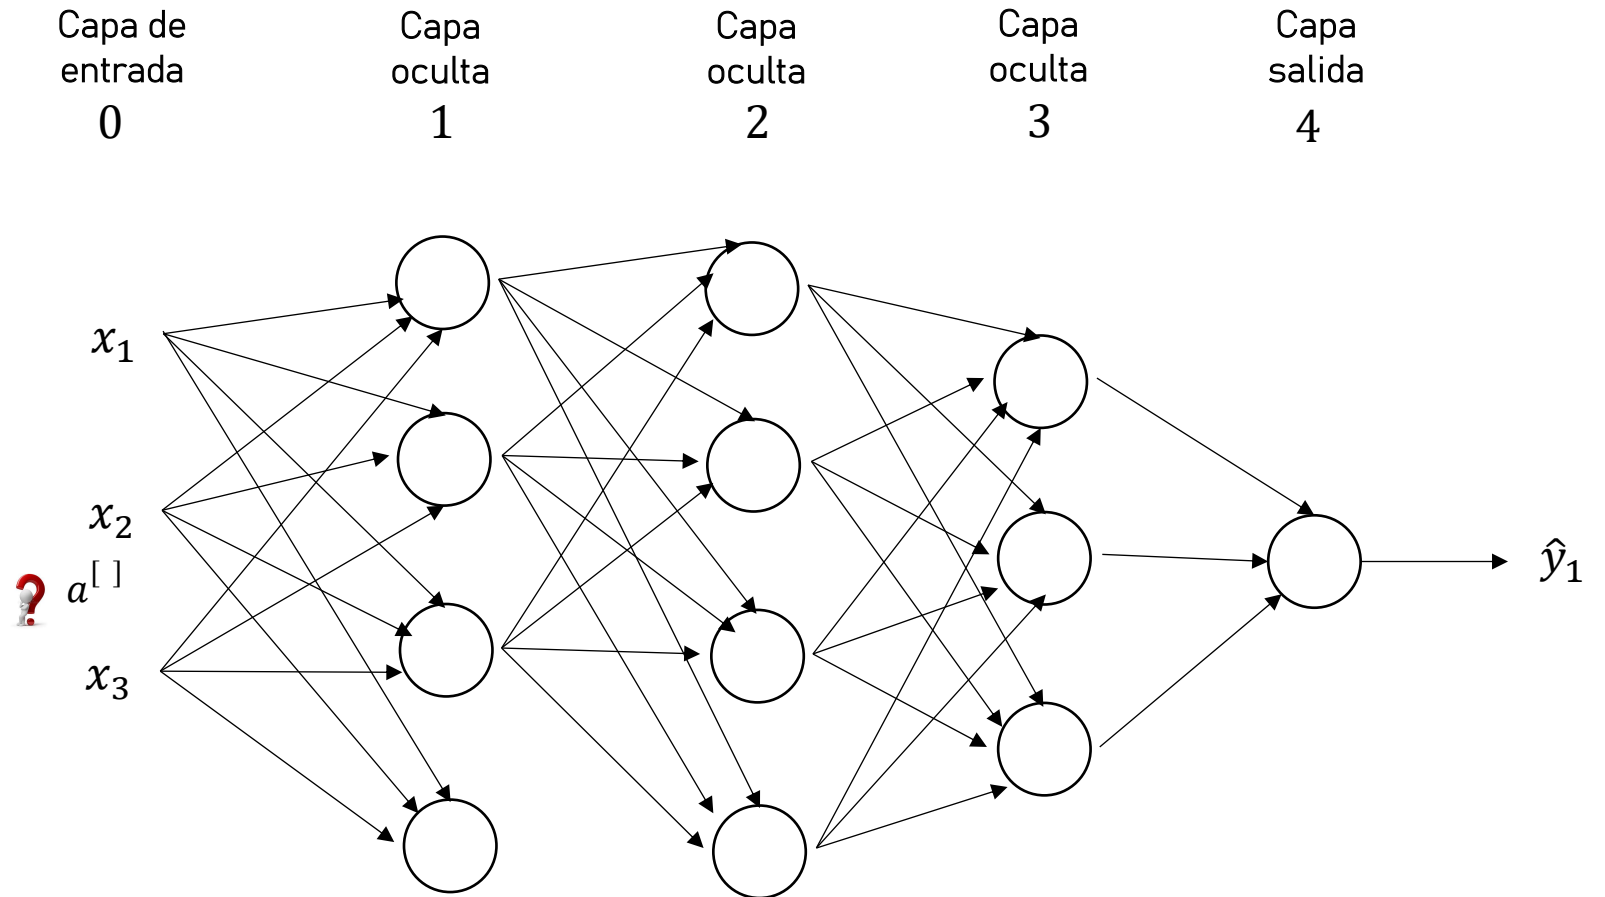


# Notación

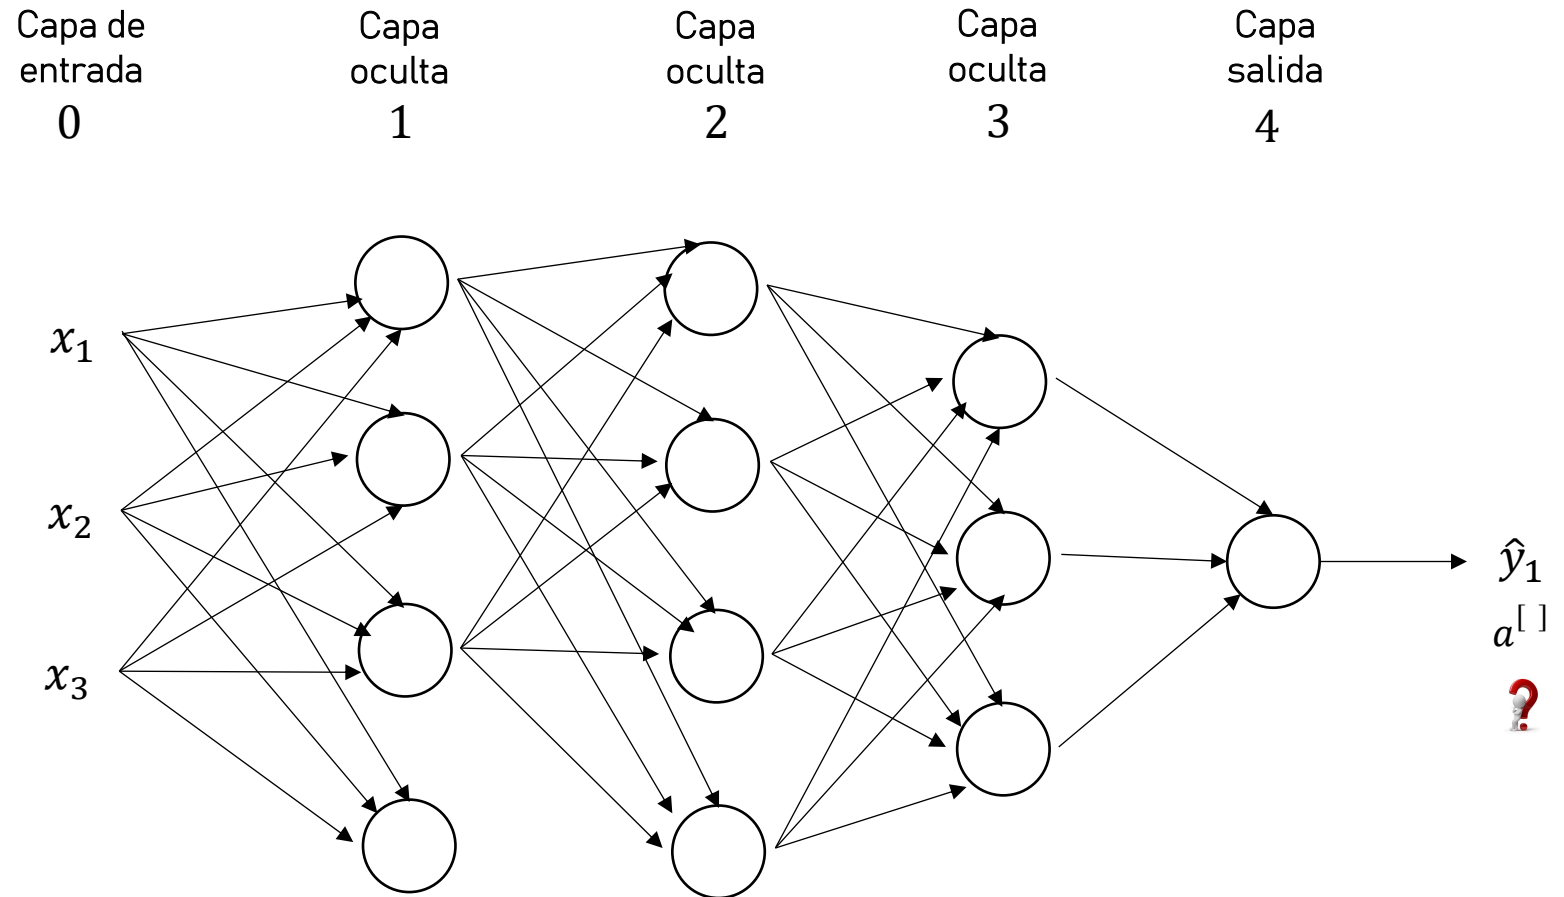




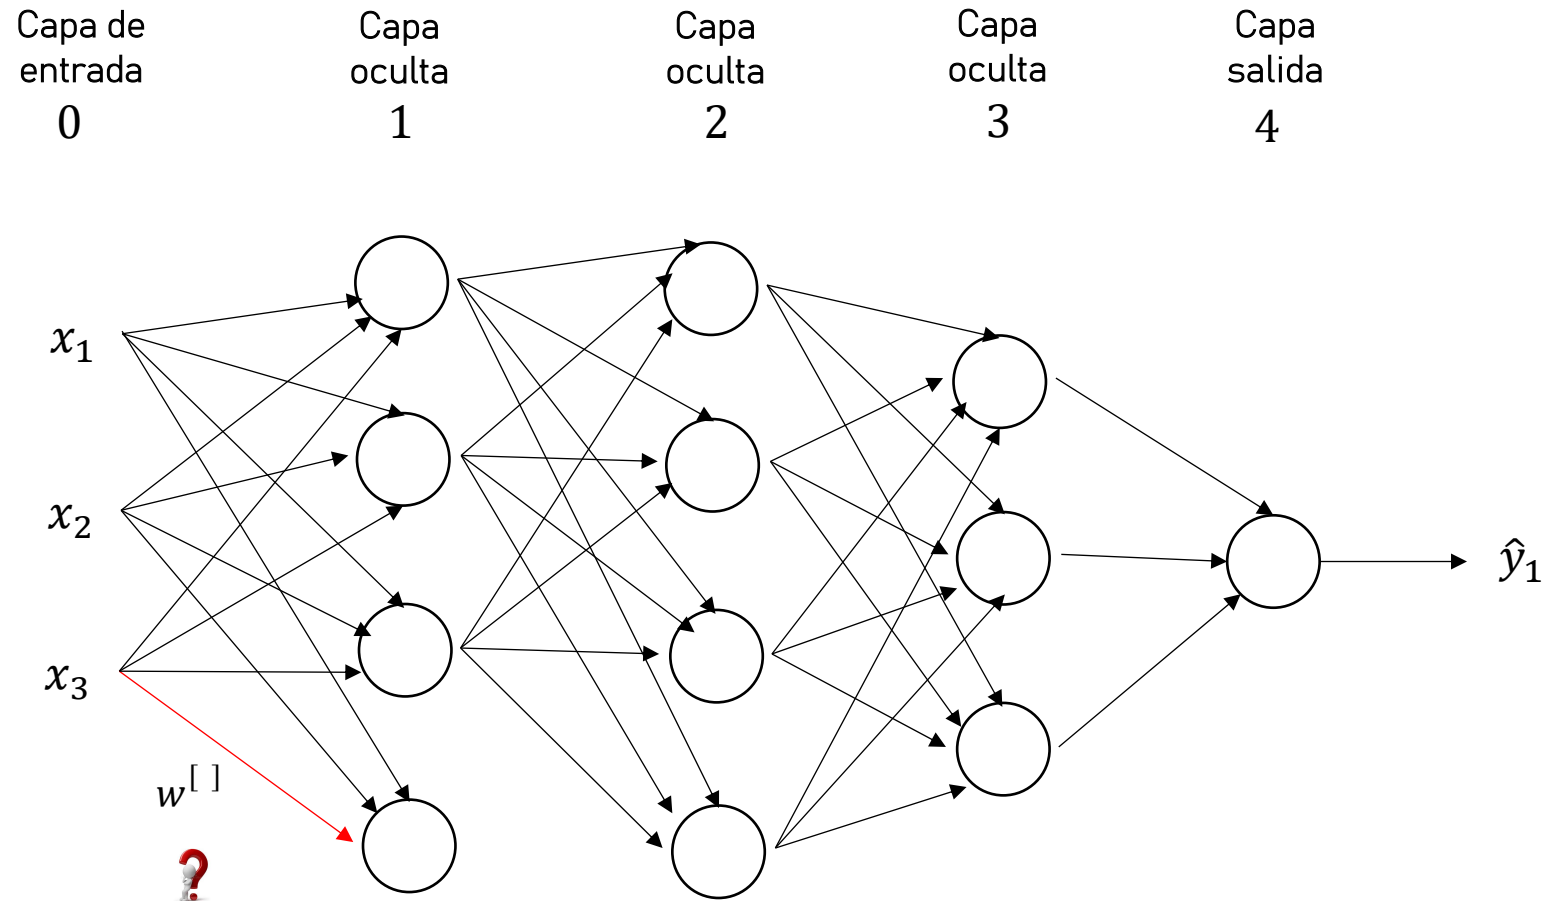
# Notación



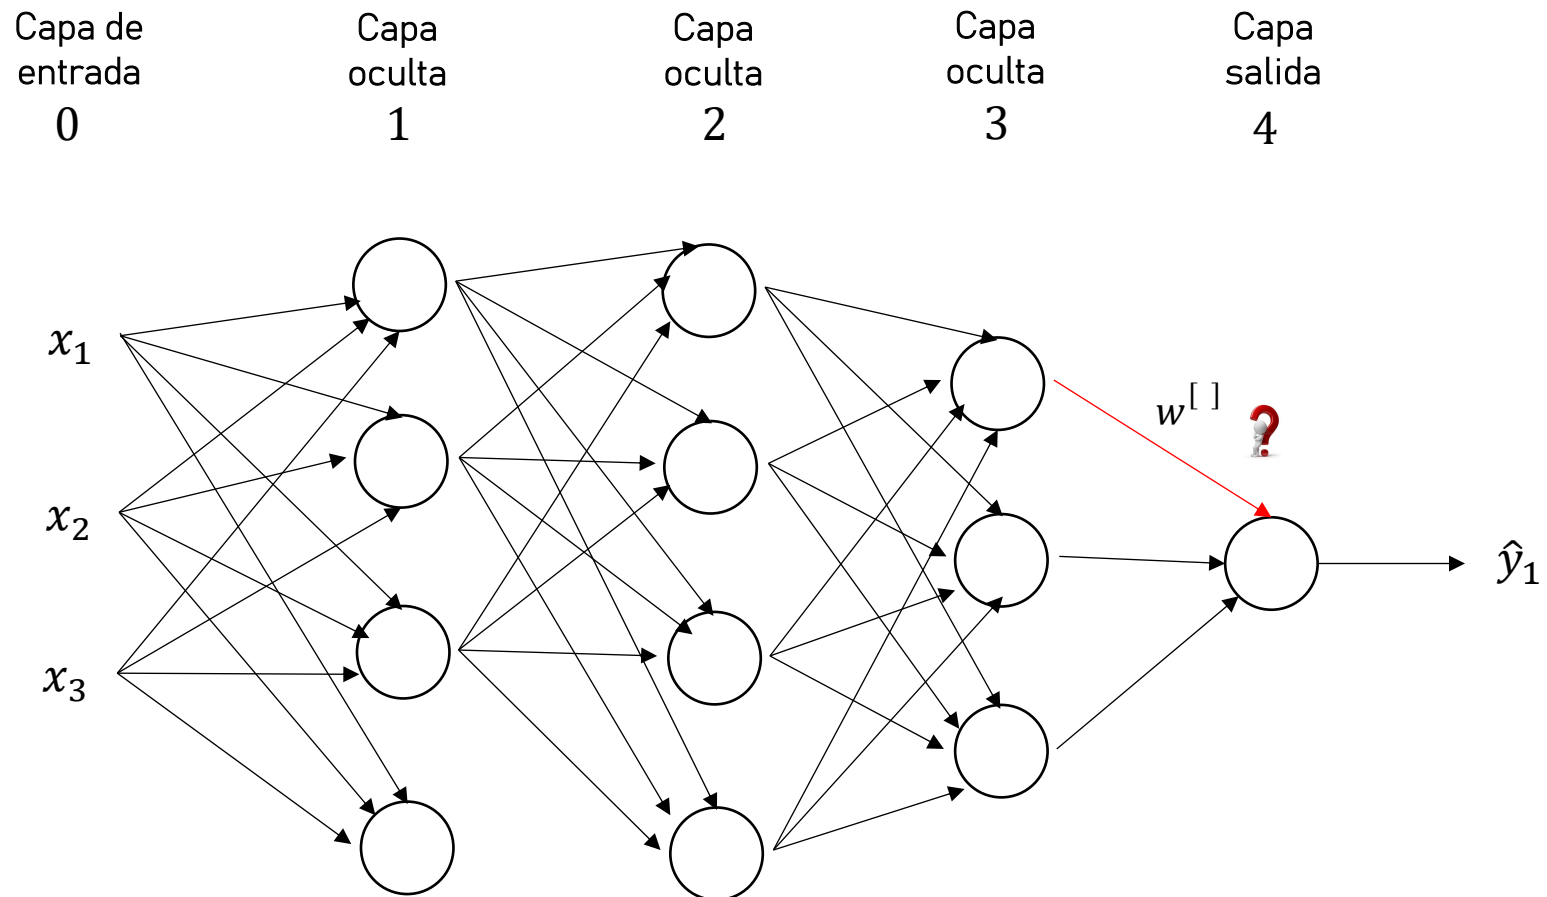
# Notación



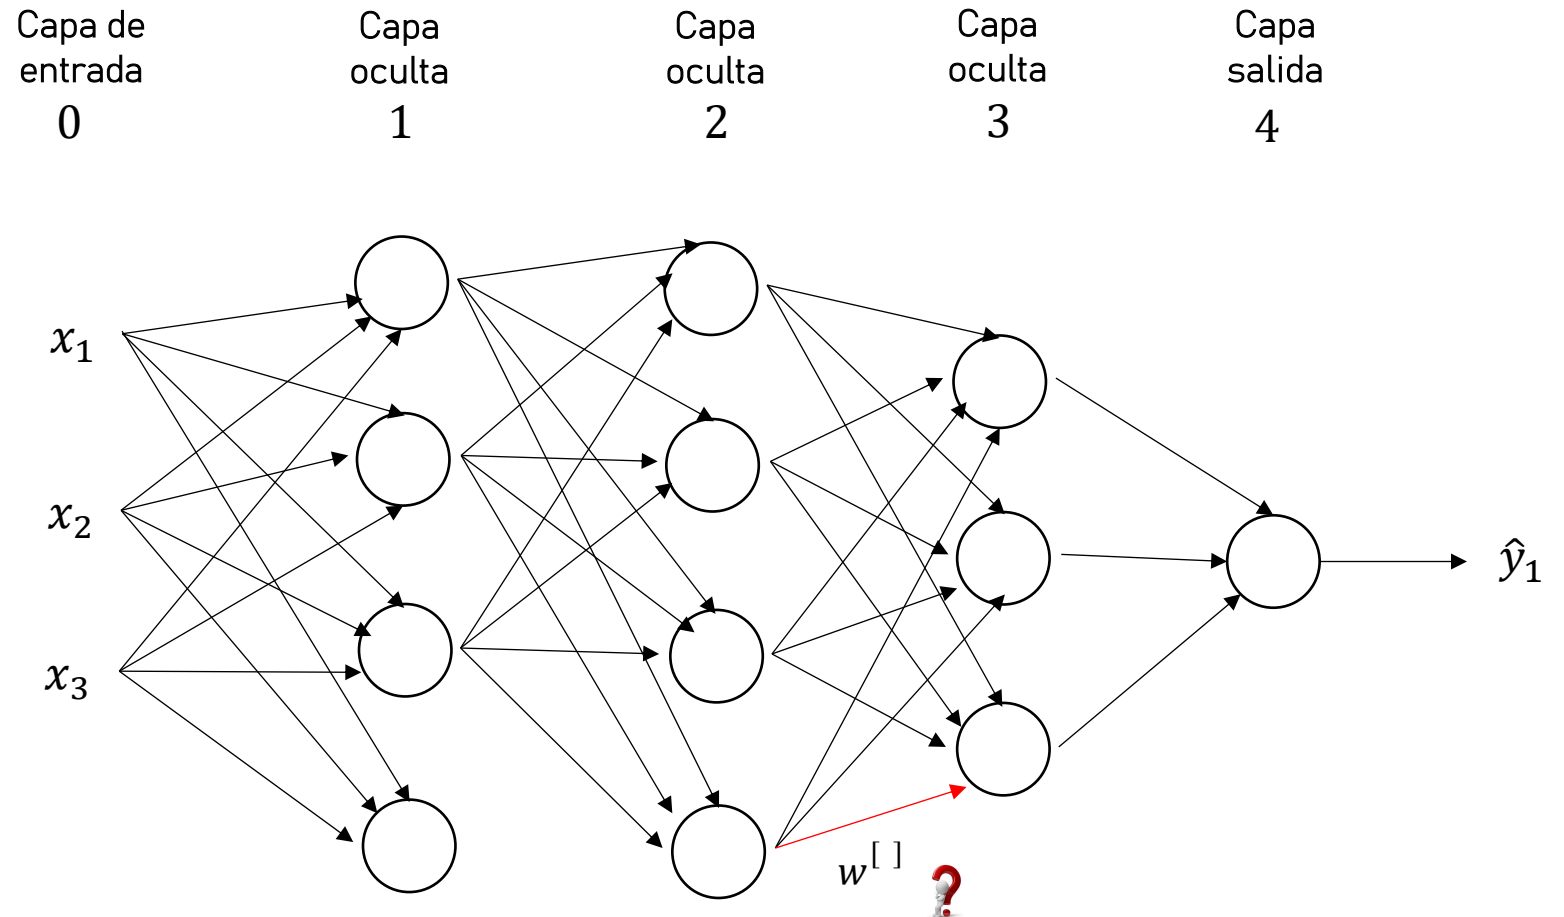
# Notación



# Notación

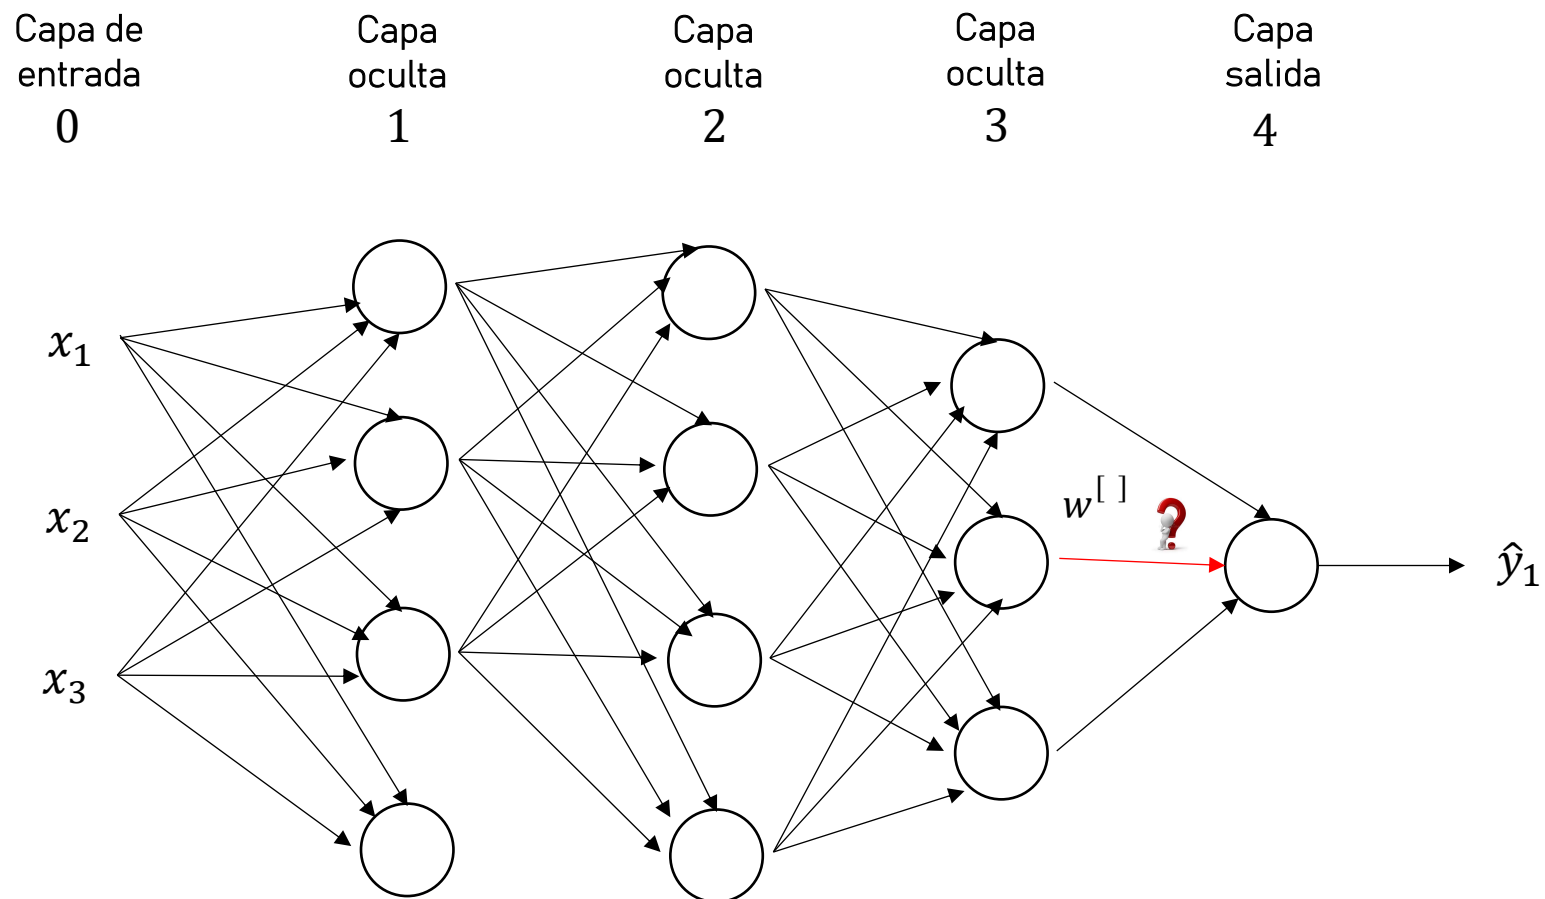


# Notación

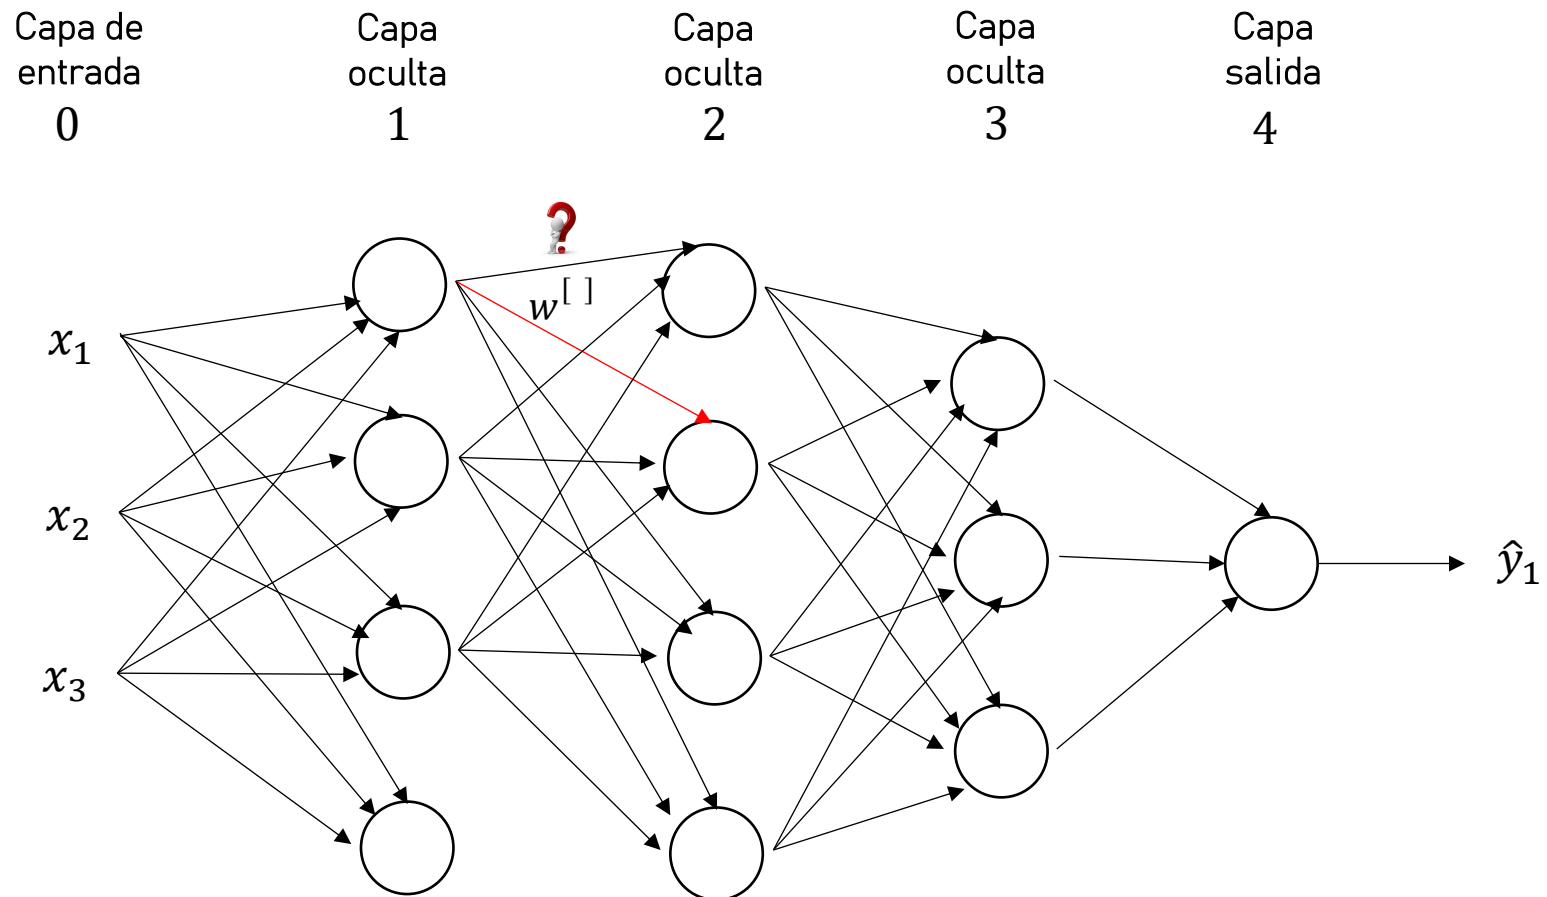




# Notación



# Notación



# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

Alternativa:

- Métodos evolutivos (neuroevolución)
  - Útil, p.ej., cuando la función de pérdida no es diferenciable.

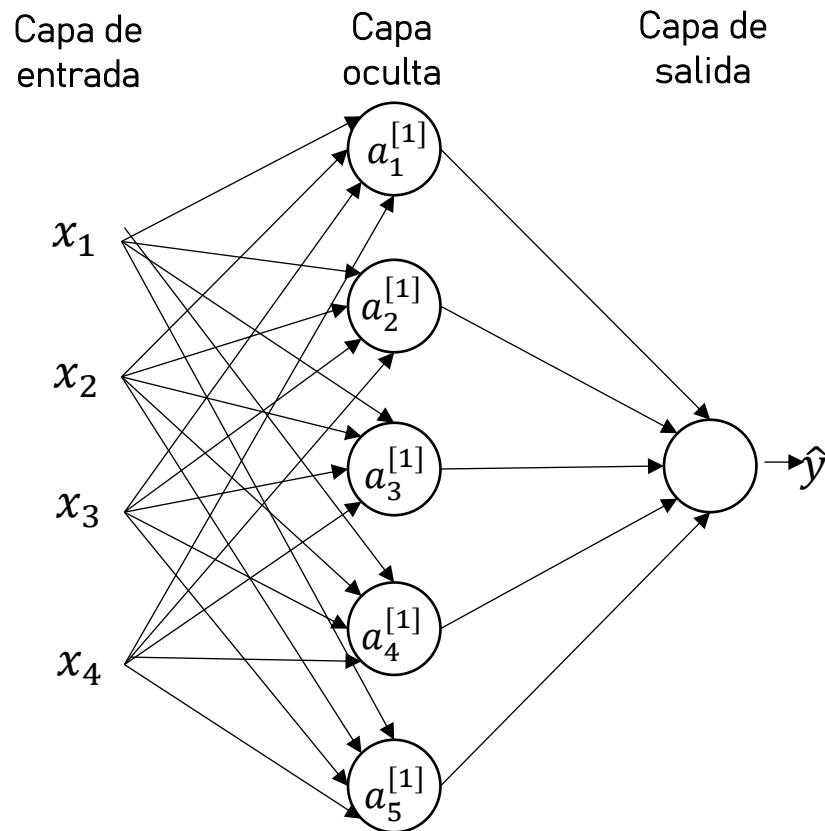
Propagación  
Hacia adelante

Propagación  
Hacia atrás

# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante



**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$ .
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

# Algoritmo de Retropropagación de errores


Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante

Capa de  
entrada

Capa  
oculta

Capa de  
salida




1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.

$$z_1^{[1]} = \sum_{i=1}^4 w_{1,i}^{[1]} x_i + b^{[1]}$$

3. Se aplica la función de activación para producir la salida de la capa.



$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.

**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

En el perceptrón original:

$$\int f(z) = \begin{cases} 1 & \text{si } z \geq 0 \\ 0 & \text{si } z < 0 \end{cases}$$


... pero, no es diferenciable.



# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante



1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.

$$z_1^{[1]} = \sum_{i=1}^4 w_{1,i}^{[1]} x_i + b^{[1]}$$

3. Se aplica la función de activación para producir la salida de la capa.

$$a_1^{[1]} = \sigma(z_1^{[1]}) = \frac{1}{1 + e^{-z_1^{[1]}}}$$

4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.

**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

En el perceptrón original:

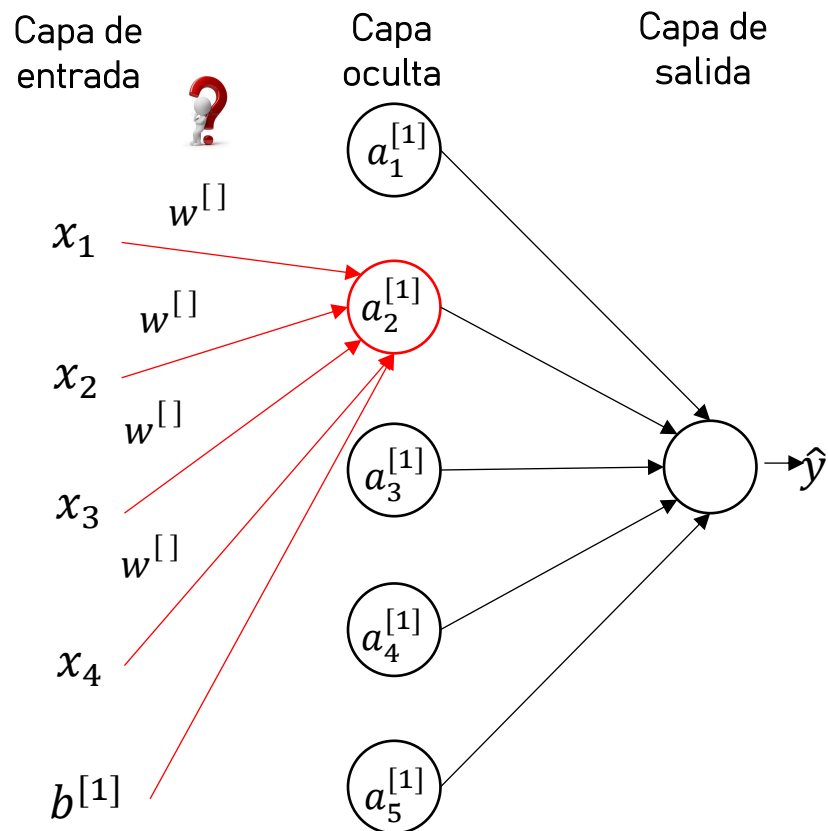
$$\boxed{\int} \cdot f(z) = \begin{cases} 1 & \text{si } z \geq 0 \\ 0 & \text{si } z < 0 \end{cases}$$

... pero, no es diferenciable.

# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante



1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.

$$z^{[l]} = \sum_{i=1}^4 w^{[l]} x_i + b^{[1]}$$

3. Se aplica la función de activación para producir la salida de la capa.

$$a_1^{[l]} = \sigma(z^{[l]}) = \frac{1}{1 + e^{-z^{[l]}}}$$

4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.


**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante



1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.

$$z_3^{[1]} = \sum_{i=1}^4 w_{3,i}^1 x_i + b^{[1]}$$

3. Se aplica la función de activación para producir la salida de la capa.

$$a_3^{[1]} = \sigma(z_3^{[1]}) = \frac{1}{1 + e^{-z_3^{[1]}}}$$

4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.

**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

# Algoritmo de Retropropagación de errores


Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante

Capa de  
entrada

Capa  
oculta

Capa de  
salida



1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.

$$z_4^{[1]} = \sum_{i=1}^4 w_{4,i}^1 x_i + b^{[1]}$$

3. Se aplica la función de activación para producir la salida de la capa.

$$a_4^{[1]} = \sigma(z_4^{[1]}) = \frac{1}{1 + e^{-z_4^{[1]}}}$$

4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.

**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

# Algoritmo de Retropropagación de errores


Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante

Capa de  
entrada

Capa  
oculta

Capa de  
salida



1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.

$$z_5^{[1]} = \sum_{i=1}^4 w_{5,i}^{[1]} x_i + b^{[1]}$$

3. Se aplica la función de activación para producir la salida de la capa.

$$a_5^{[1]} = \sigma(z_5^{[1]}) = \frac{1}{1 + e^{-z_5^{[1]}}}$$

4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.

**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

# Algoritmo de Retropropagación de errores


Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante

Capa de  
entrada

Capa  
oculta

Capa de  
salida



1. Los datos de entrada alimentan la red, capa por capa.

2. En cada capa, se calcula la suma pesada de las entradas más el sesgo.



3. Se aplica la función de activación para producir la salida de la capa.



4. Este proceso continúa hasta que la capa de salida produce la predicción de la red.


**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

## Propagación Hacia adelante



5. Cálculo del error: Se calcula el error en la capa de salida entre la predicción de la red y el valor esperado.

$$E = \frac{1}{2} \sum_{j=1}^J \sum_{k=1}^K (y_{j,k} - \hat{y}_{j,k})^2$$

Error cuadrático medio

Para  $J = \text{\#ejemplos}$  y  $K = \text{\#salidas}$

En este caso  $J = 1$  y  $K = 1$

$$E = \frac{1}{2} (y - \hat{y})^2$$

**Meta:** Obtener el error de la red considerando todos los ejemplos disponibles.

- Calculamos el valor de  $\hat{Y}$ , para los datos de entrada  $X$
- Calculamos el error entre  $Y$  y  $\hat{Y}$ .

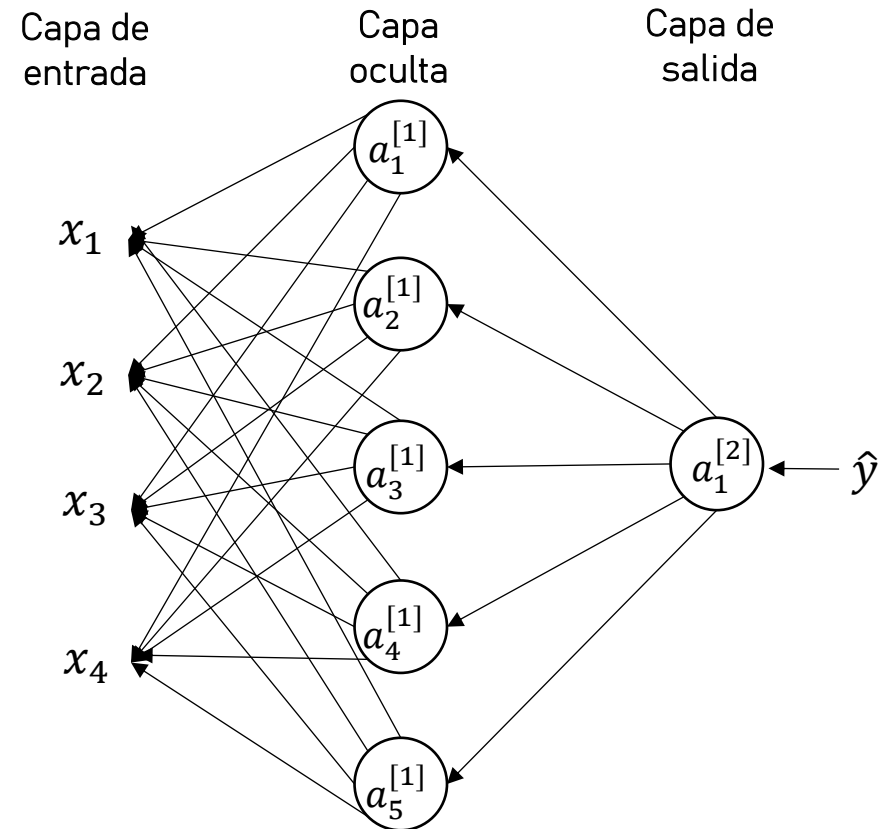
# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

Propagación  
Hacia atrás

Meta: Calcular los pesos  $W$  y sesgos  $B$ , de tal forma que se minimice la función del error.

$$E = \frac{1}{2} \sum_{j=1}^J \sum_{k=1}^K (y_{j,k} - \hat{y}_{j,k})^2$$



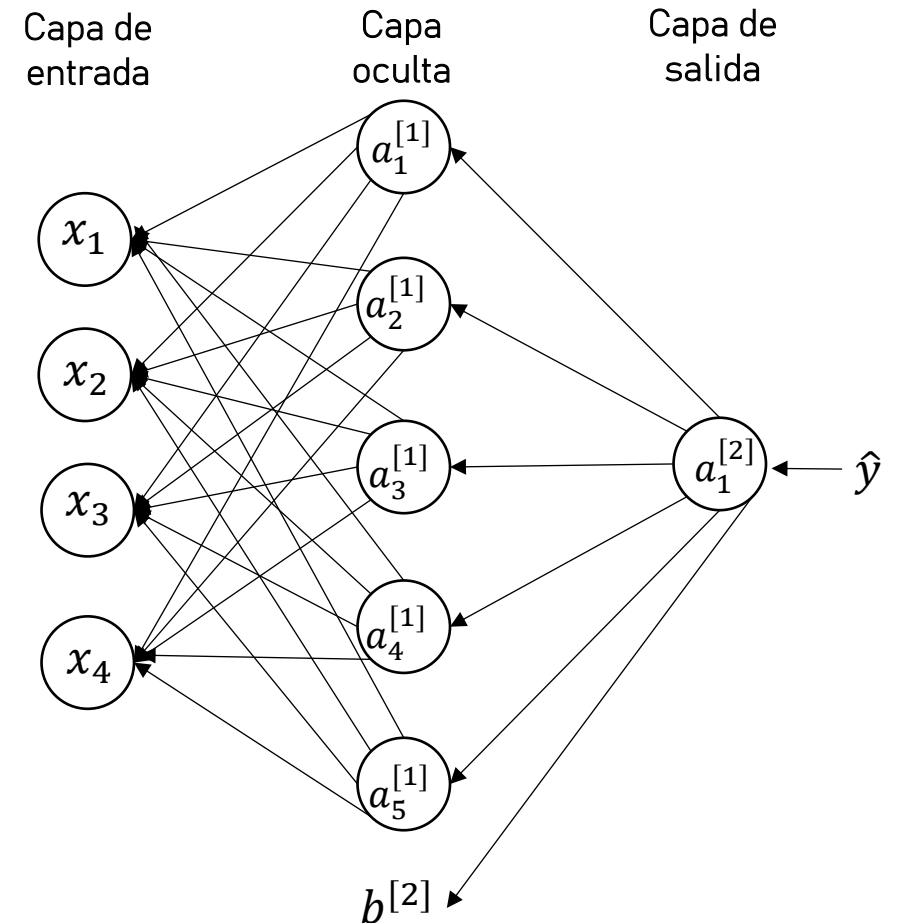


# Algoritmo de Retropropagación de errores

Es el algoritmo central usado para entrenar a la mayoría de las ANN.

Propagación  
Hacia atrás

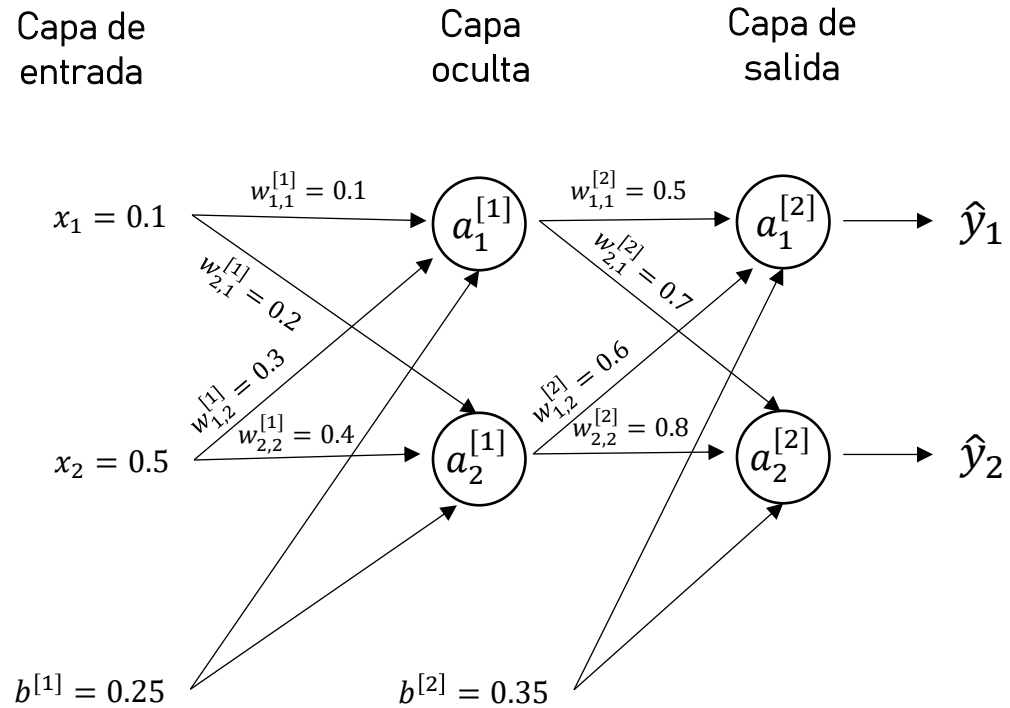
1. **Cálculo de los gradientes:** A partir del error obtenido en la propagación hacia adelante, se deriva la función de pérdida con respecto a las salidas de la red. Esto nos dice cuánto cambia el error si se cambian un poco las salidas.
2. **Propagación del error:** Este error se propaga hacia atrás de la red, capa por capa. Usando la regla de la cadena, se calcula el gradiente de la pérdida con respecto a los pesos y sesgos de cada capa. Esto implica que debemos calcular el gradiente local de cada neurona (derivada de la función de activación) y luego multiplicarlo por el gradiente del error de la capa subsecuente.
3. **Actualización de pesos y sesgos:** Una vez que se calcularon todos los gradientes de la pérdida con respecto a todos los pesos y sesgos, estos gradientes se usan para optimizar los pesos y los sesgos usando un algoritmo de optimización (p.ej. **descenso por gradiente**). La regla de actualización normalmente implica restar una pequeña fracción del gradiente (escalado por la tasa de aprendizaje) a el valor actual del parámetro.



Meta: Calcular los pesos  $W$  y sesgos  $B$ , de tal forma que se minimice la función del error.

# Perceptrones Multicapa y Retropropagación

## Ejemplo



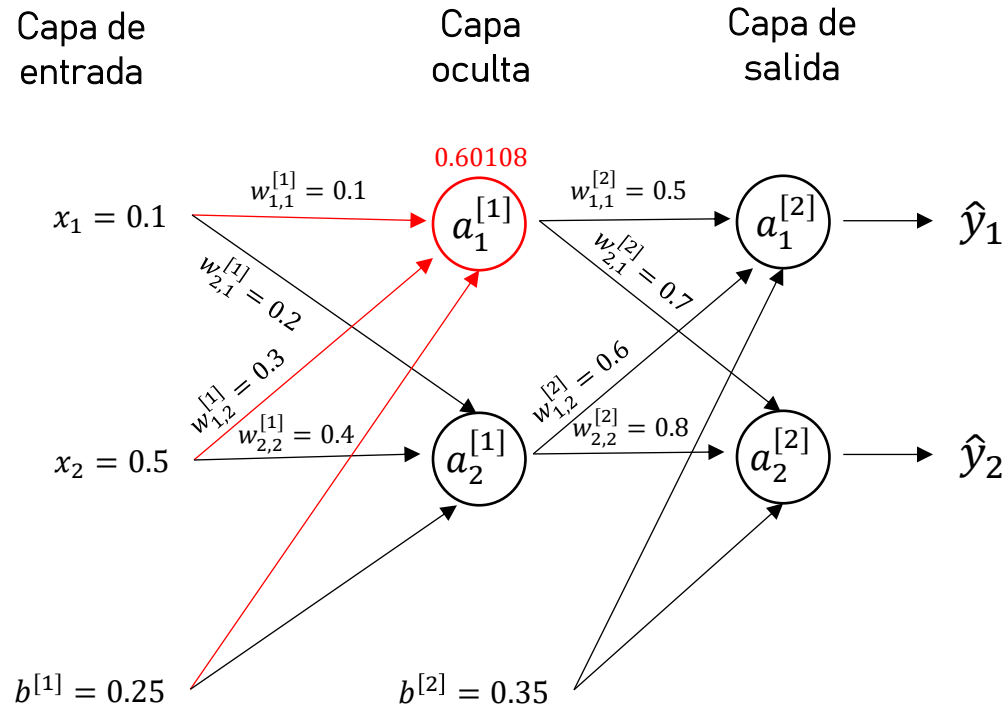
- Las neuronas de la capa oculta usan la función de activación sigmoide.
- Las neuronas de la capa de salida usa la función lineal.

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_1^{[1]}$



$$z_1^{[1]} = w_{1,1}^{[1]}x_1 + w_{1,2}^{[1]}x_2 + b^{[1]}$$
$$= (0.1)(0.1) + (0.3)(0.5) + 0.25 = 0.41$$


$$a_1^{[1]} = \sigma(z_1^{[1]}) = \frac{1}{1 + e^{-z_1^{[1]}}}$$
$$= \frac{1}{1 + e^{-0.41}} = 0.60108$$

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_2^{[1]}$



$$z_2^{[1]} = ?$$


$$a_2^{[1]} = \sigma(z_2^{[1]}) = \frac{1}{1 + e^{-z_2^{[1]}}} = ?$$

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_2^{[1]}$



$$z_2^{[1]} = w_{2,1}^{[1]}x_1 + w_{2,2}^{[1]}x_2 + b^{[1]}$$
$$= (0.2)(0.1) + (0.4)(0.5) + 0.25 = 0.47$$

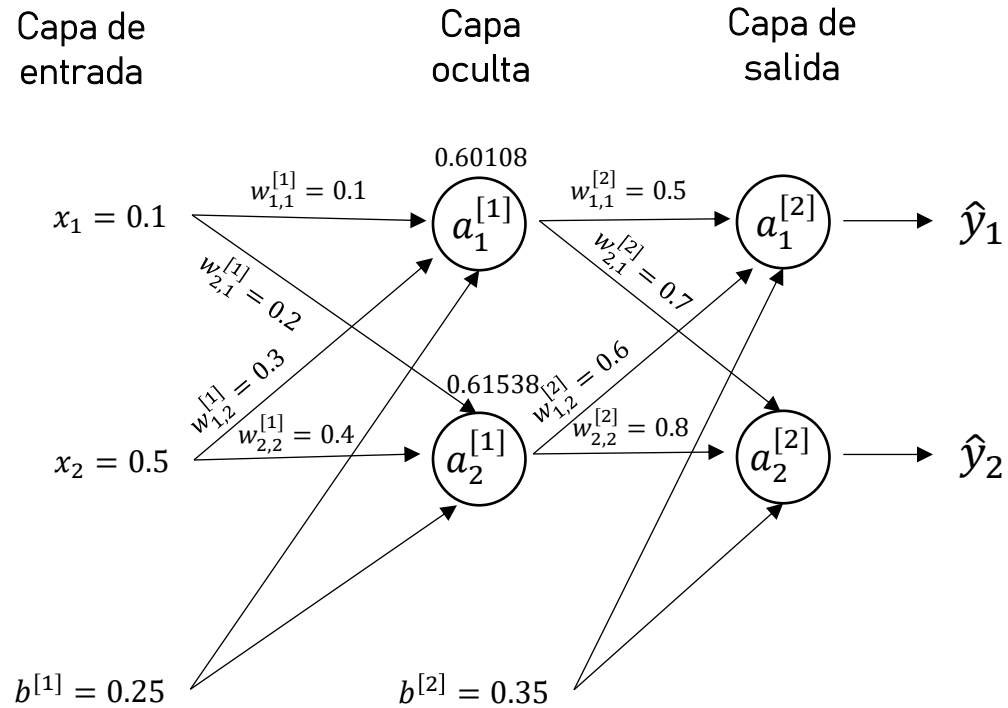
$$a_2^{[1]} = \sigma(z_2^{[1]}) = \frac{1}{1 + e^{-z_2^{[1]}}}$$
$$= \frac{1}{1 + e^{-0.47}} = 0.61538$$

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_1^{[2]}$



$$z_1^{[2]} = ?$$

$$a_1^{[2]} = \sigma(z_1^{[2]}) = \frac{1}{1 + e^{-z_1^{[2]}}} =$$


?

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_1^{[2]}$



$$z_1^{[2]} = w_{1,1}^{[2]}x_1 + w_{1,2}^{[2]}x_2 + b^{[2]}$$

$$= (0.5)(0.60108) + (0.6)(0.61538) + 0.35 \\ = 1.019768$$

$$a_1^{[2]} = \sigma(z_1^{[2]}) = \frac{1}{1 + e^{-z_1^{[2]}}}$$

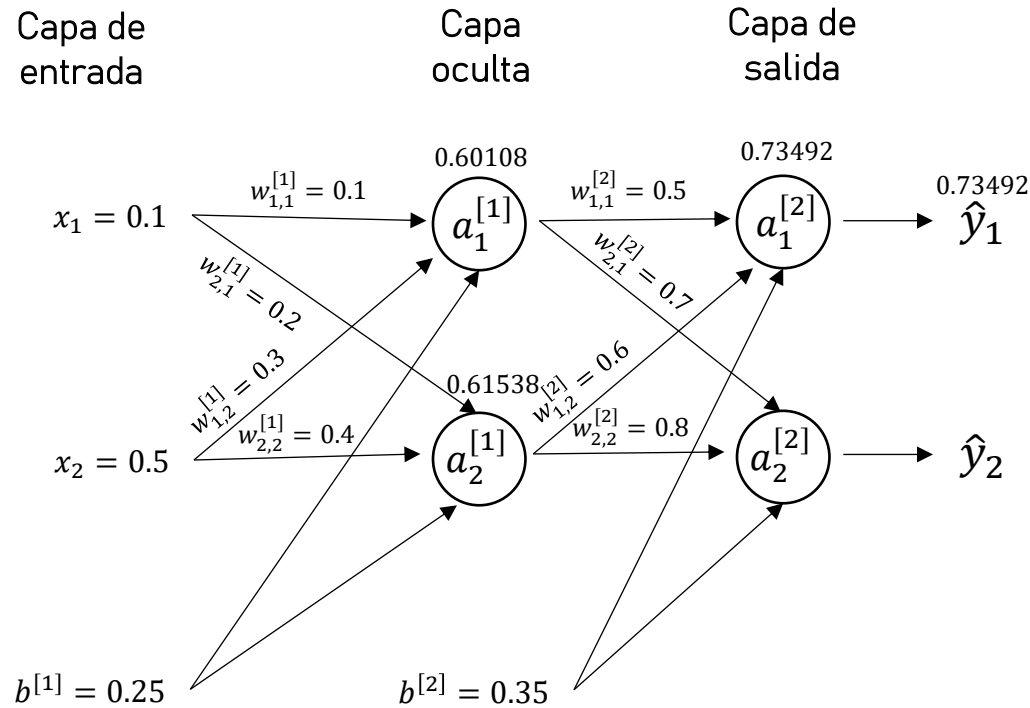
$$= \frac{1}{1 + e^{-1.019768}} = 0.73492$$

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_1^{[2]}$



$$z_2^{[2]} = ?$$

$$a_2^{[2]} = \sigma(z_2^{[2]}) = \frac{1}{1 + e^{-z_2^{[2]}}} =$$

?




# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos  $a_1^{[2]}$



$$z_2^{[2]} = w_{2,1}^{[2]}x_1 + w_{2,2}^{[2]}x_2 + b^{[2]}$$

$$= (0.7)(0.60108) + (0.8)(0.61538) + 0.35$$
$$= 1.26306$$

$$a_1^{[2]} = \sigma(z_1^{[2]}) = \frac{1}{1 + e^{-z_1^{[2]}}}$$

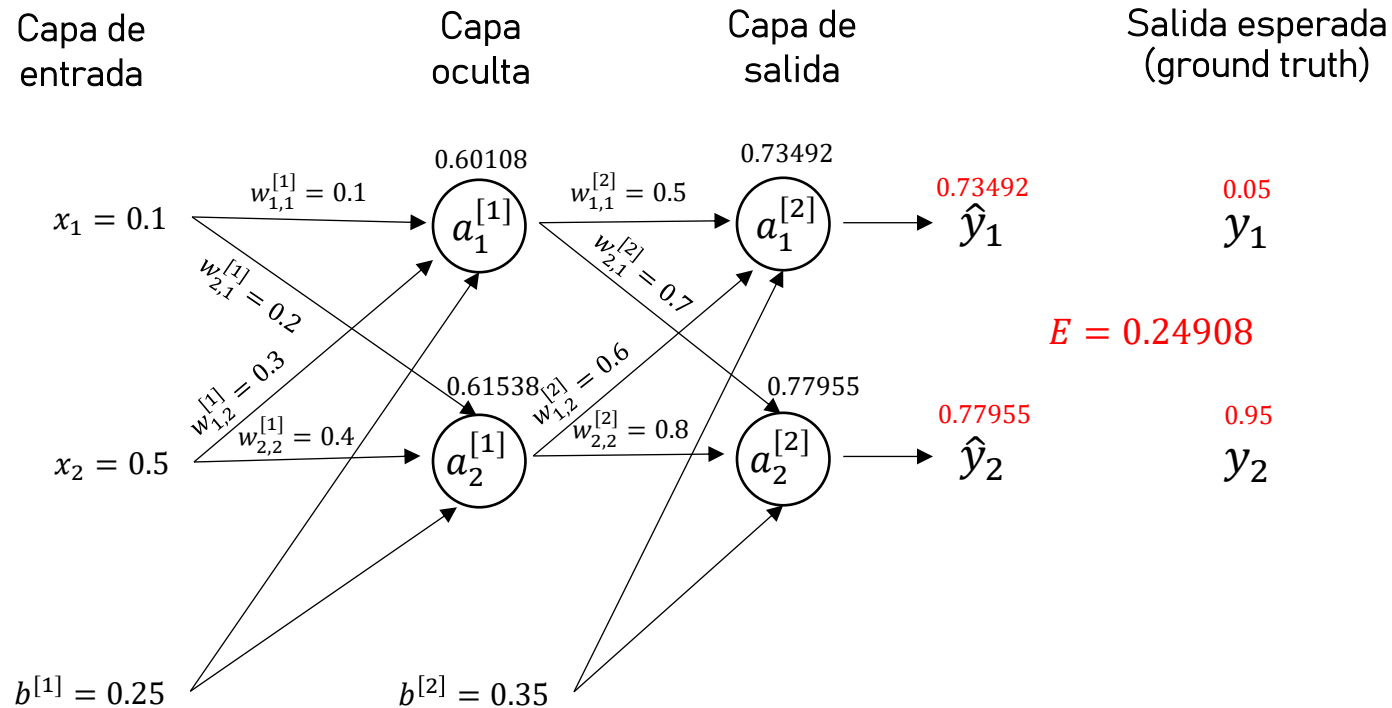
$$= \frac{1}{1 + e^{-1.26306}} = 0.77955$$

# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia adelante

Calculamos el error



$$E = \frac{1}{2} \sum_{j=1}^J \sum_{k=1}^K (y_{j,k} - \hat{y}_{j,k})^2$$

En este ejemplo  $J = 1$  y  $K = 2$

$$\begin{aligned} E &= \frac{1}{2} \sum_{k=1}^K (y_k - \hat{y}_k)^2 \\ &= \frac{1}{2} ((0.05 - 0.73492)^2 + (0.95 - 0.77955)^2) \\ &= \frac{1}{2} ((-0.68492)^2 + (0.17045)^2) \\ &= \frac{1}{2} (0.46911 + 0.02905) = \frac{0.46911}{2} + \frac{0.02905}{2} \\ &= 0.23456 + 0.01452 = 0.24908 \end{aligned}$$

# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,1}^{[2]} = 0.5$  en  $E$ ?

$E$  está siendo afectado por  $\hat{y}_1$

$\hat{y}_1$  está siendo afectado por  $a_1^{[2]} \rightarrow z_1^{[2]}$

$z_1^{[2]}$  está siendo afectado por  $w_{1,1}^{[2]}$

Por la regla de la cadena:

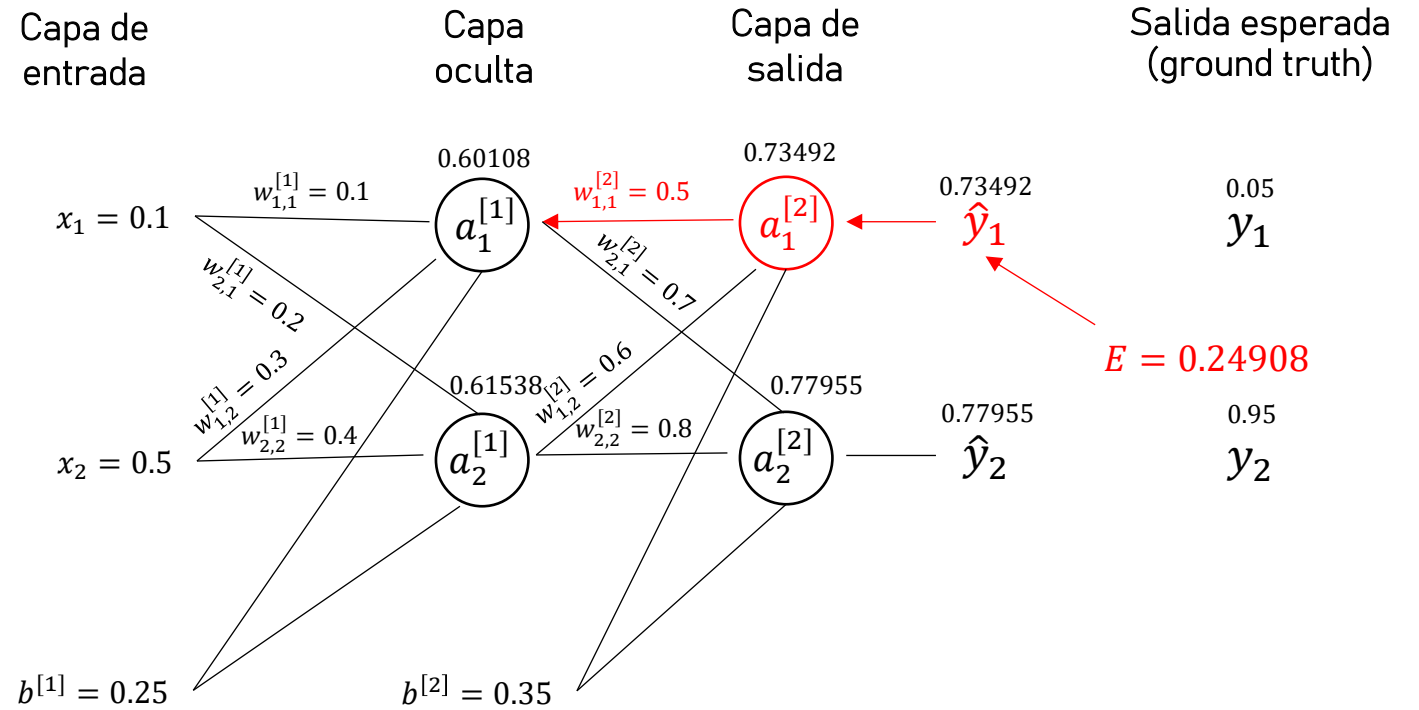
¿Cómo cambia  $E$   
conforme cambia  
 $w_{1,1}^{[2]}$ ?

¿Cómo cambia  $\hat{y}_1$   
conforme cambia  
 $a_1^{[2]}$ ?

$$\frac{dE}{dw_{1,1}^{[2]}} = \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \frac{dz_1^{[2]}}{dw_{1,1}^{[2]}}$$

¿Cómo cambia  $E$   
conforme  
cambia  $\hat{y}_1$ ?

¿Cómo cambia  
 $a_1^{[2]}$  conforme  
cambia  $w_{1,1}^{[2]}$ ?



# Perceptrones Multicapa y Retropropagación

## Ejemplo

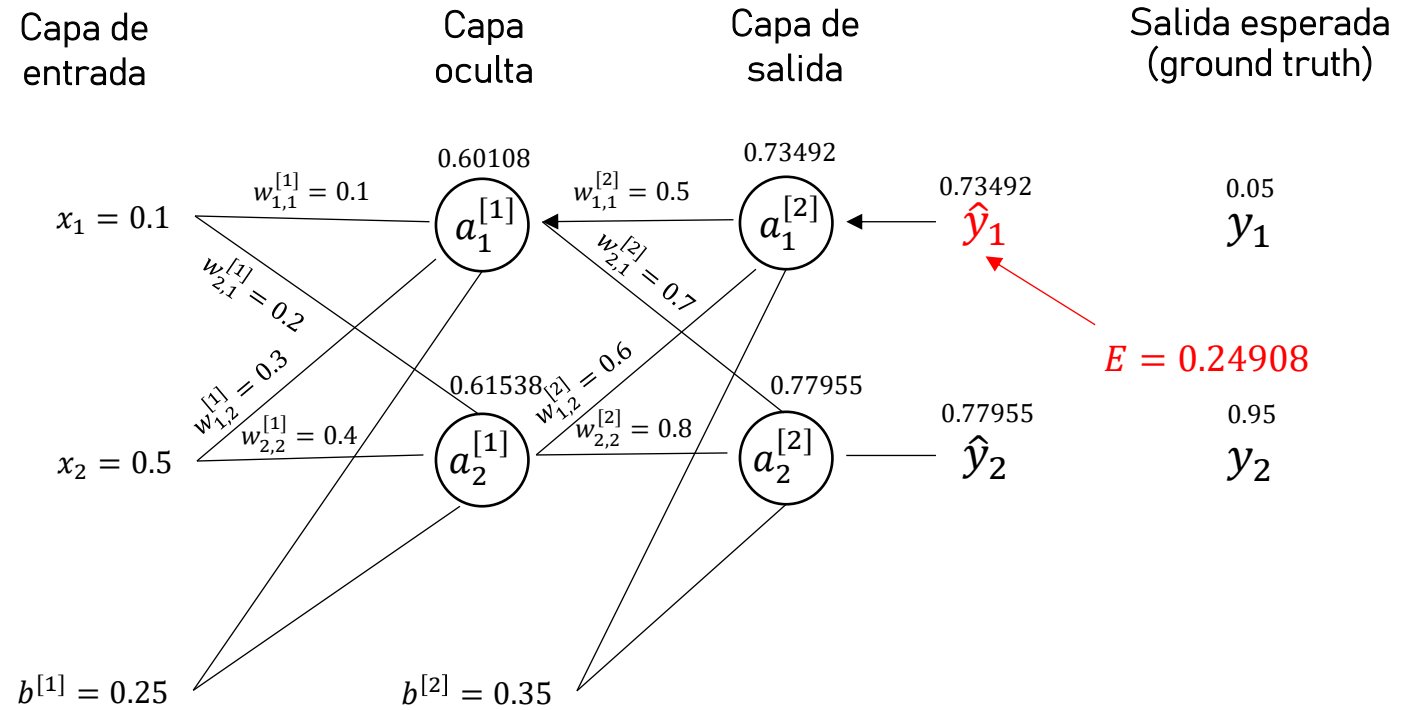
### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,1}^{[2]} = 0.5$  en  $E$ ?

$$\frac{dE}{dw_{1,1}^{[2]}} = \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \frac{dz_1^{[2]}}{dw_{1,1}^{[2]}}$$

$$E = \frac{(y_1 - \hat{y}_1)^2}{2} + \frac{(y_2 - \hat{y}_2)^2}{2}$$

$$\begin{aligned} \frac{dE}{d\hat{y}_1} &= \frac{2(y_1 - \hat{y}_1)}{2} (-1) = \hat{y}_1 - y_1 \\ &= 0.73492 - 0.05 \\ &= -0.68492 \end{aligned}$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,1}^{[2]} = 0.5$  en  $E$ ?

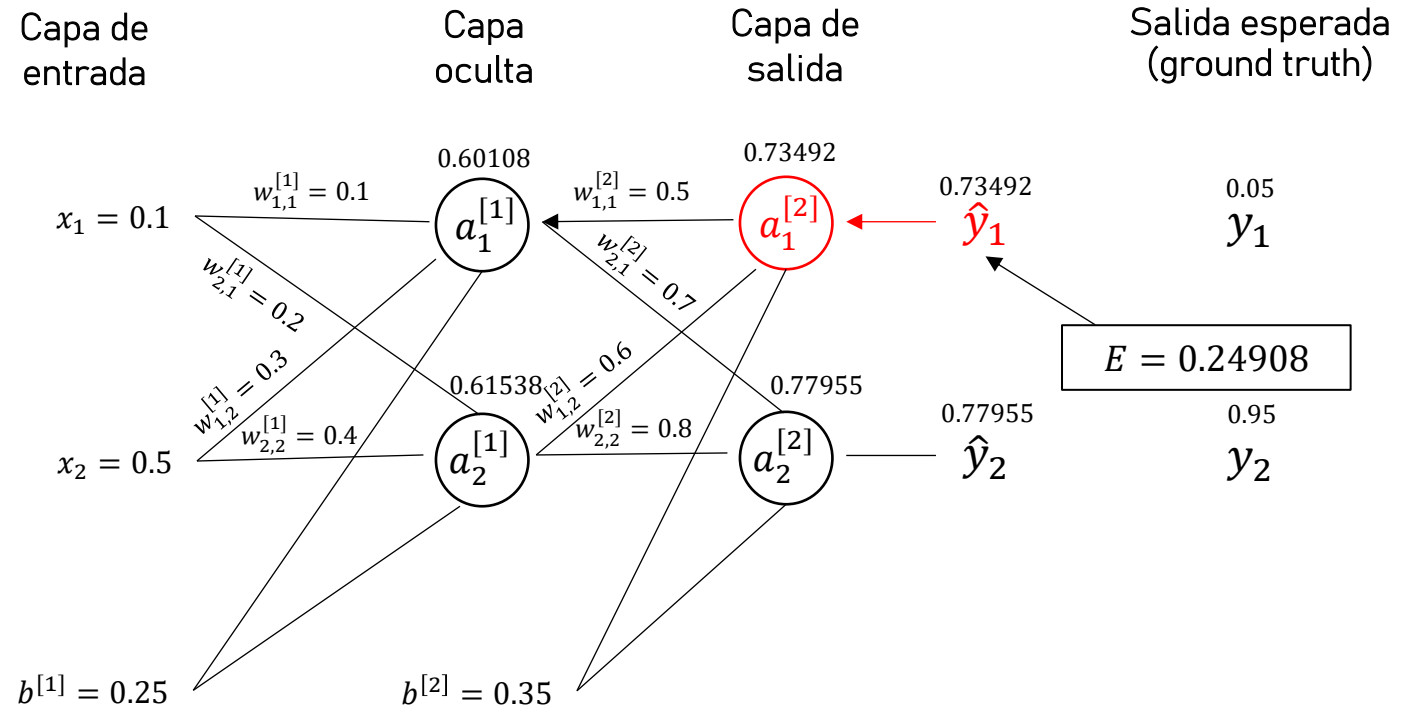
$$\frac{dE}{dw_{1,1}^{[2]}} = \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \frac{dz_1^{[2]}}{dw_{1,1}^{[2]}}$$

$$\hat{y}_1 = a_1^{[2]} = \sigma(z_1^{[2]}) = \frac{1}{1 + e^{-z_1^{[2]}}}$$

$$\frac{d\hat{y}_1}{dz_1^{[2]}} = ?$$

Calcular:

$$\frac{d}{dx} \sigma(x)$$



# Nota

## Derivada de la función sigmoide

$$\sigma(x) = \frac{1}{1 + e^{-x}} = (1 + e^{-x})^{-1}$$

$$\sigma'(x) = -1 \cdot (1 + e^{-x})^{-2} \cdot \underbrace{\frac{d}{dx}(1 + e^{-x})}_{-e^{-x}}$$

$$= (1 + e^{-x})^{-2} \cdot e^{-x}$$

$$= \frac{e^{-x}}{(1 + e^{-x})^2}$$

Nota:

$$D_x e^u = e^u D_x u$$

$$\begin{aligned} \text{Como } \sigma(x) &= \frac{1}{1+e^{-x}} \quad \text{y} \quad 1 - \sigma(x) = 1 - \frac{1}{1+e^{-x}} \\ &= \frac{1+e^{-x}}{1+e^{-x}} - \frac{1}{1+e^{-x}} \\ &= \frac{1+e^{-x} - 1}{1+e^{-x}} \\ &= \frac{e^{-x}}{1+e^{-x}} \end{aligned}$$

$$\sigma(x)(1 - \sigma(x)) = \frac{e^{-x}}{(1 + e^{-x})^2}$$

Por lo tanto:

$$\boxed{\sigma'(x) = \sigma(x)(1 - \sigma(x))}$$

- Evita tener exponentes negativos en la fórmula,
- hace explícito que la derivada depende solo de  $\sigma(x)$ ,  $\sigma(x)\sigma(x)$ ,
- y se usa mucho en redes neuronales para ahorrar cálculos.

# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,1}^{[2]} = 0.5$  en  $E$ ?


$$\frac{dE}{dw_{1,1}^{[2]}} = \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \frac{dz_1^{[2]}}{dw_{1,1}^{[2]}}$$

$$\hat{y}_1 = a_1^{[2]} = \sigma(z_1^{[2]}) = \frac{1}{1 + e^{-z_1^{[2]}}}$$

$$\frac{d\hat{y}_1}{dz_1^{[2]}} = \sigma(z_1^{[2]}) (1 - \sigma(z_1^{[2]}))$$

Nota:  $\frac{d}{dx} \sigma(x) = \sigma(x)(1 - \sigma(x))$

$$= \hat{y}_1 (1 - \hat{y}_1) = 0.73492(1 - 0.73492) = 0.19480$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

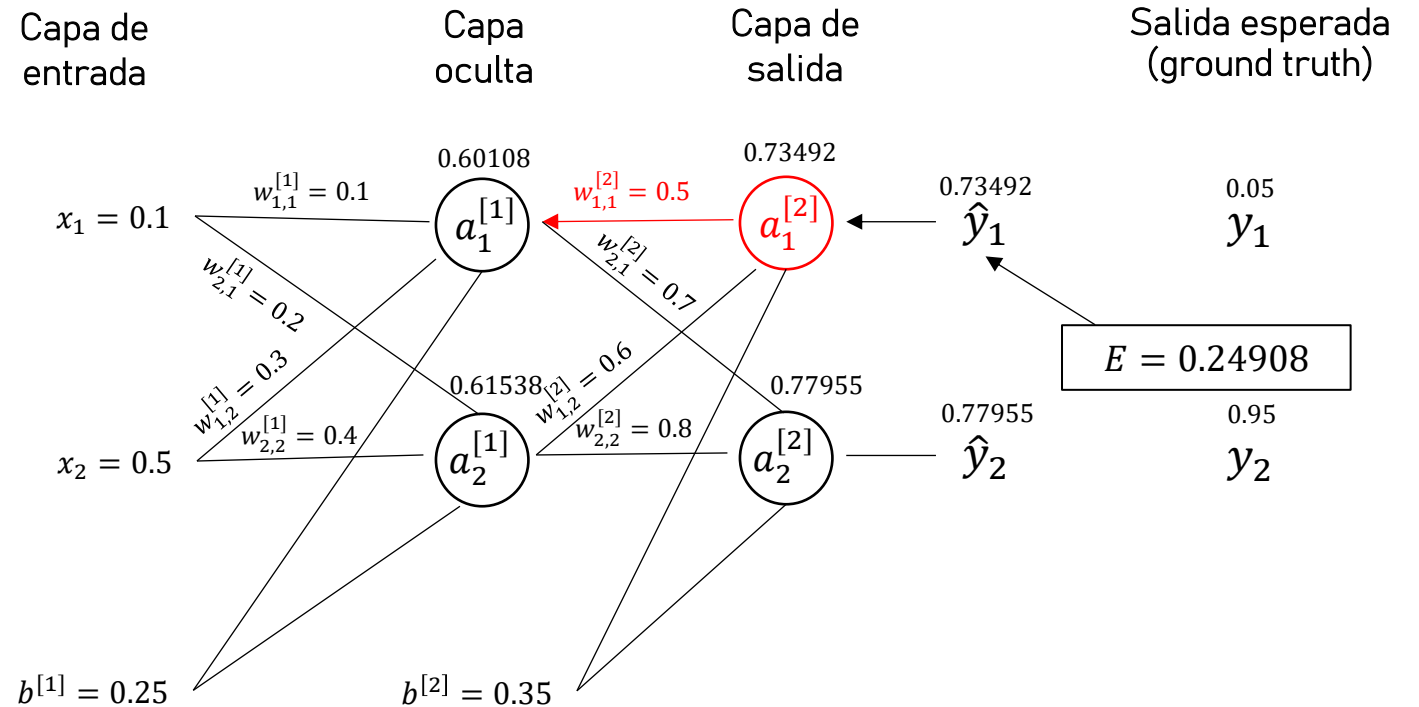
### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,1}^{[2]} = 0.5$  en  $E$ ?

$$\frac{dE}{dw_{1,1}^{[2]}} = \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \boxed{\frac{dz_1^{[2]}}{dw_{1,1}^{[2]}}}$$

$$z_1^{[2]} = w_{1,1}^{[2]} a_1^{[1]} + w_{1,2}^{[2]} a_2^{[1]} + b^{[2]}$$

$$\frac{dz_1^{[2]}}{dw_{1,1}^{[2]}} = a_1^{[1]} = \boxed{0.60108}$$






# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,1}^{[2]} = 0.5$  en  $E$ ?

$$\begin{aligned}\frac{dE}{dw_{1,1}^{[2]}} &= \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \frac{dz_1^{[2]}}{dw_{1,1}^{[2]}} \\ &= 0.68492 * 0.1980 * 0.60108 \\ &= 0.0802\end{aligned}$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

Actualizamos  $w_{1,1}^{[2]}$

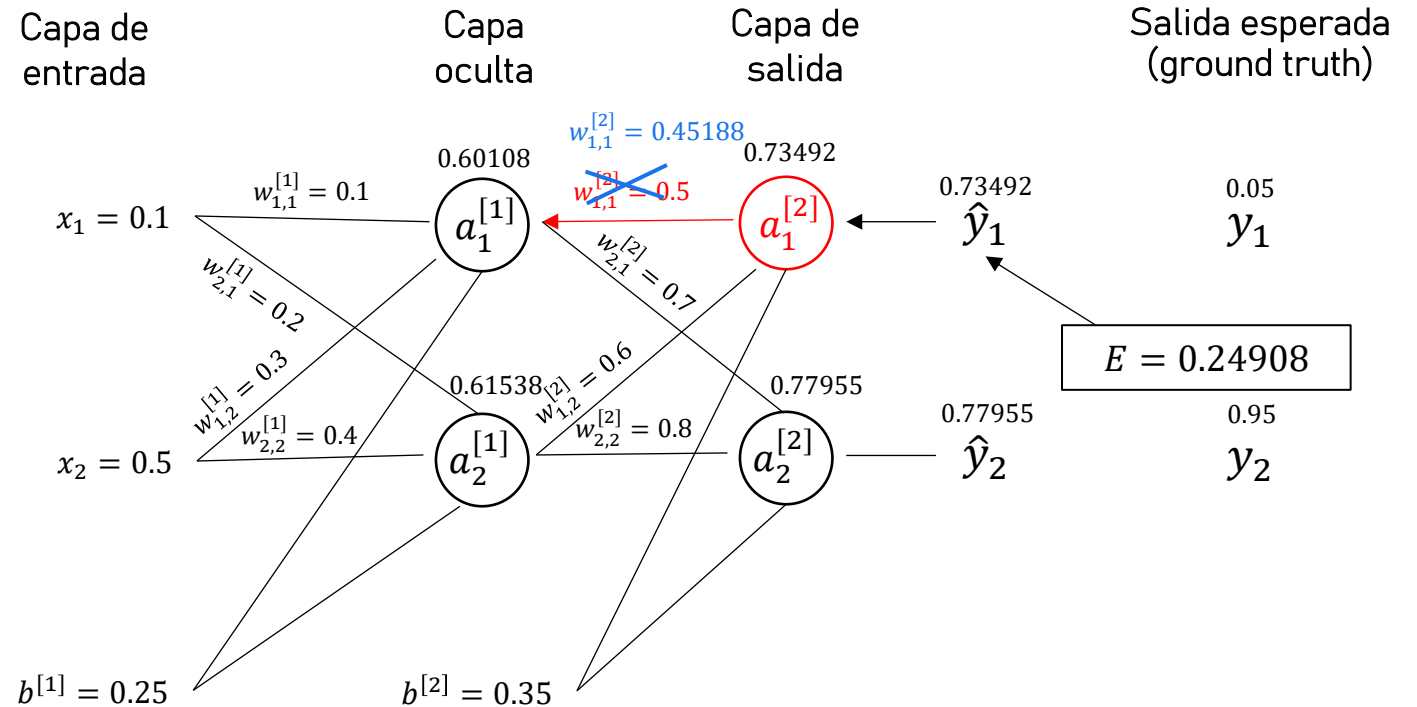
$$\eta = 0.6$$

$$w_{1,1}^{[2]} = w_{1,1}^{[2]} - \eta \left( \frac{dE}{dw_{1,1}^{[2]}} \right)$$

$$= 0.5 - 0.6(0.0802)$$

$$= 0.5 - 0.04812$$

$$= 0.45188$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

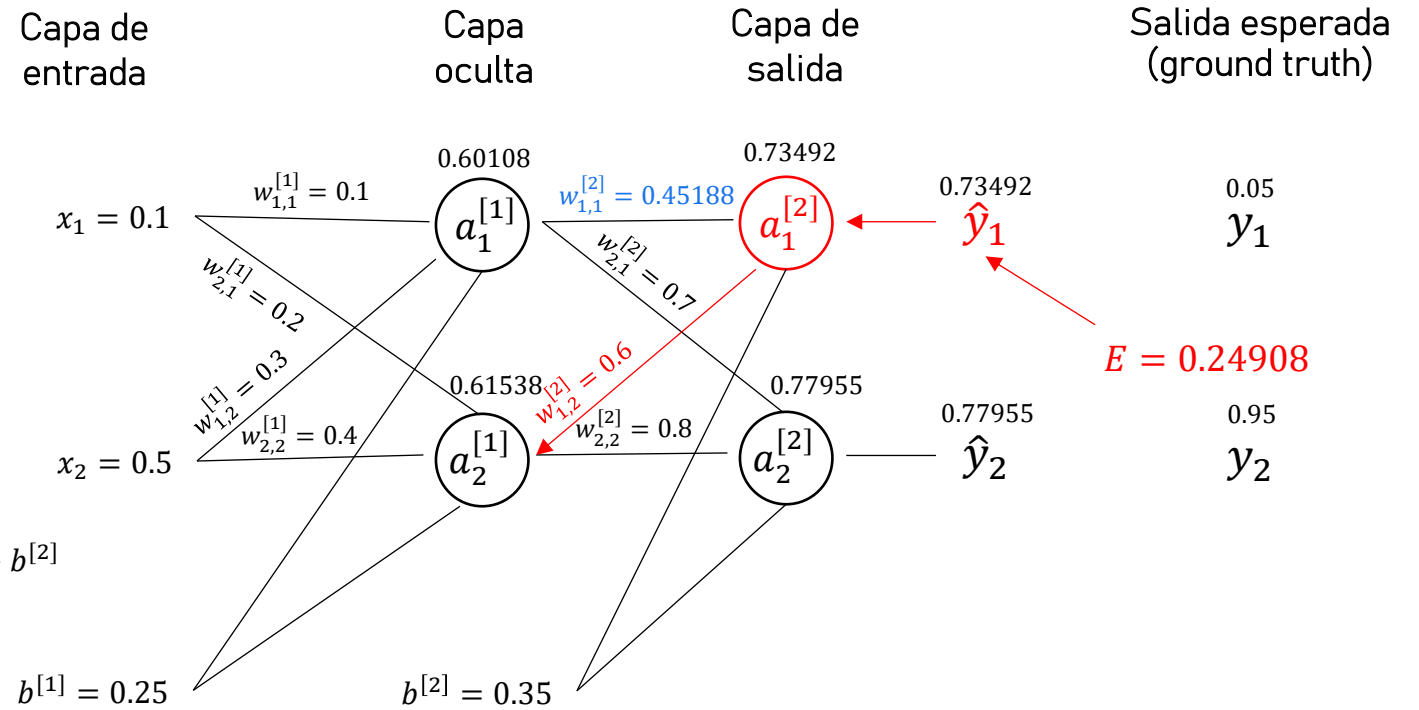
### Propagación Hacia atrás

¿Cuánto contribuye  $w_{1,2}^{[2]} = 0.6$  en  $E$ ?

$$\frac{dE}{dw_{1,2}^{[2]}} = \frac{dE}{d\hat{y}_1} \frac{d\hat{y}_1}{dz_1^{[2]}} \frac{dz_1^{[2]}}{dw_{1,2}^{[2]}}$$

$\downarrow$  0.68492 ✓       $\downarrow$  0.19480 ✓       $\downarrow$   $z_1^{[2]} = w_{1,1}^{[2]}a_1^{[1]} + w_{1,2}^{[2]}a_2^{[1]} + b^{[2]}$   
 $\downarrow$   $a_2^{[1]} = 0.61538$

= 0.08211



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

Actualizamos  $w_{1,2}^{[2]}$


$$\eta = 0.6$$

$$w_{1,2}^{[2]} = w_{1,2}^{[2]} - \eta \left( \frac{dE}{dw_{1,2}^{[2]}} \right)$$

$$= 0.6 - 0.6(0.08211)$$

$$= 0.6 - 0.04926$$

$$= 0.55073$$



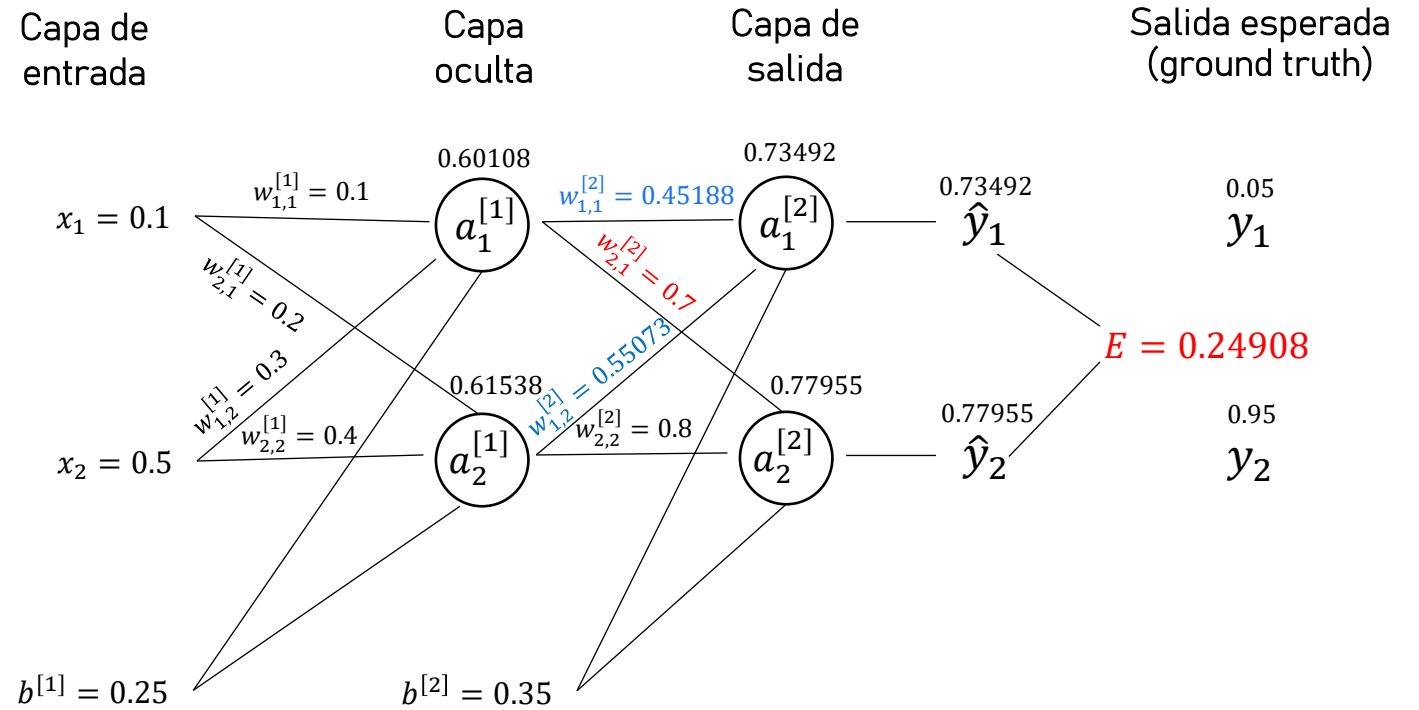
# Perceptrones Multicapa y Retropropagación

## Ejemplo

Propagación  
Hacia atrás

¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?



# Perceptrones Multicapa y Retropropagación


## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo


### Propagación Hacia atrás

¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$

?



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

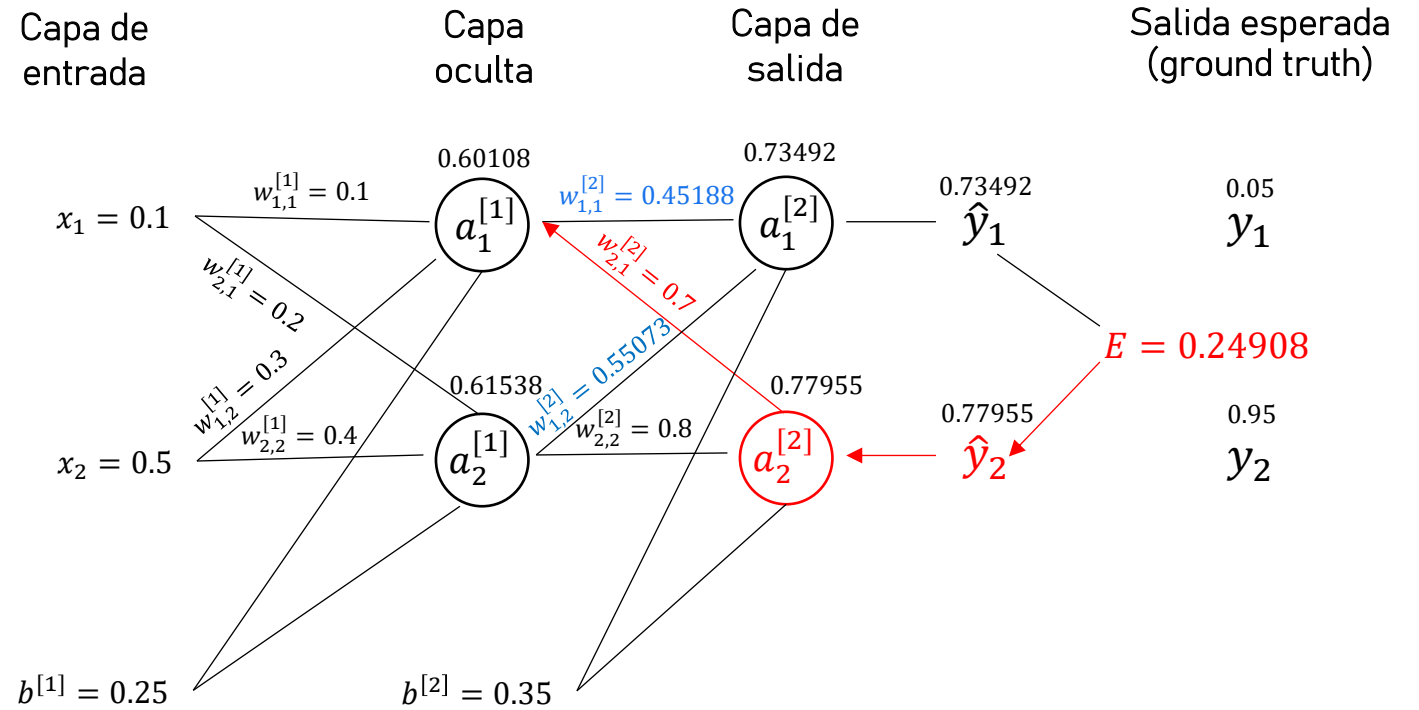
¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$



$$E = \frac{(y_1 - \hat{y}_1)^2}{2} + \frac{(y_2 - \hat{y}_2)^2}{2}$$

$$\begin{aligned} \frac{dE}{d\hat{y}_2} &= \frac{2(y_2 - \hat{y}_2)}{2} (-1) = \hat{y}_2 - y_2 \\ &= 0.77955 - 0.95 \\ &= -0.17044 \end{aligned}$$





# Perceptrones Multicapa y Retropropagación

## Ejemplo


### Propagación Hacia atrás

¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$

?



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

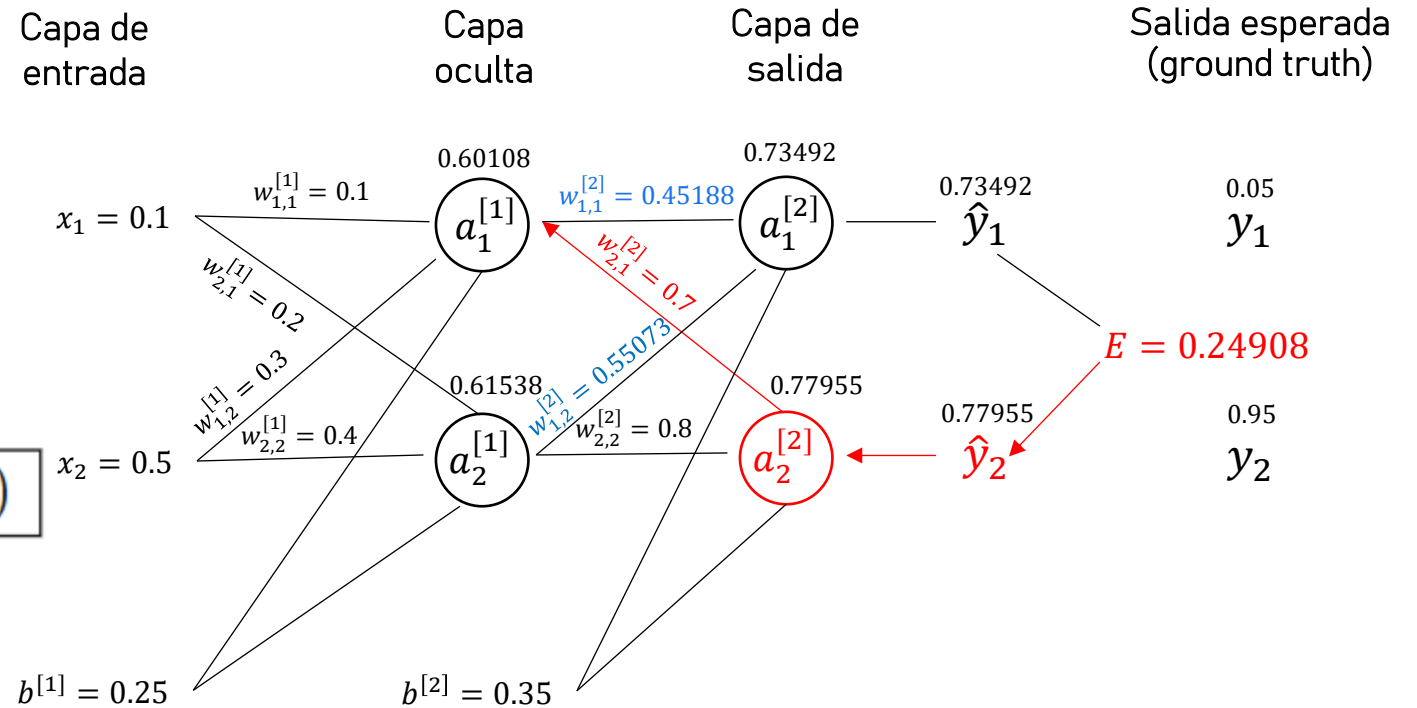
¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$

$$\hat{y}_2 = \sigma(z_2^{[2]}) \quad \sigma'(x) = \sigma(x)(1 - \sigma(x))$$

$$\begin{aligned} \frac{d\hat{y}_2}{dz_2^{[2]}} &= \sigma(z_2^{[2]}) (1 - \sigma(z_2^{[2]})) \\ &= 0.77955(1 - 0.77955) \\ &= 0.17184 \end{aligned}$$



# Perceptrones Multicapa y Retropropagación


## Ejemplo

### Propagación Hacia atrás

¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás


¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \boxed{\frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}}$$

$$z_2^{[2]} = w_{2,1}^{[2]} a_1^{[1]} + w_{2,2}^{[2]} a_2^{[1]}$$

$$\frac{dz_2^{[2]}}{dw_{2,1}^{[2]}} = a_1^{[1]} = \boxed{0.60108}$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás


¿Cuánto contribuye  $w_{2,1}^{[2]} = 0.7$  en  $E$ ?

¿Qué derivada hay que calcular?

$$\frac{dE}{dw_{2,1}^{[2]}} = \frac{dE}{d\hat{y}_2} \frac{d\hat{y}_2}{dz_2^{[2]}} \frac{dz_2^{[2]}}{dw_{2,1}^{[2]}}$$

$$= -0.17044 * 0.17184 * 0.60108$$

$$= -0.01760$$



# Perceptrones Multicapa y Retropropagación

## Ejemplo

### Propagación Hacia atrás

Actualizamos  $w_{2,1}^{[2]}$


$$\eta = 0.6$$

$$w_{2,1}^{[2]} = w_{2,1}^{[2]} - \eta \left( \frac{dE}{dw_{2,1}^{[2]}} \right)$$

$$= 0.7 - 0.6(-0.01760)$$

$$= 0.7 + 0.01056$$

$$= \boxed{0.71056}$$



# Perceptrones Multicapa y Retropropagación

Actualizar los pesos  $w_{1,1}^{[1]}$ ,  $w_{2,1}^{[1]}$ ,  $w_{1,2}^{[1]}$  y  $w_{2,2}^{[1]}$



Enviarlos por email a [weam@turing.iimas.unam.mx](mailto:weam@turing.iimas.unam.mx)